

**HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG**  
**KHOA CÔNG NGHỆ THÔNG TIN**

---



**BÁO CÁO CUỐI KÌ**

**Đề tài: Finetune mô hình dịch máy Neural cho văn  
bản chuyên ngành y khoa Anh-Việt**

|                              |                          |
|------------------------------|--------------------------|
| <b>Lớp tín chỉ:</b>          | <b>D23CQCN04-B</b>       |
| <b>Giảng viên hướng dẫn:</b> | <b>TS. Kim Ngọc Bách</b> |
| <b>Sinh viên thực hiện:</b>  | <b>Nguyễn Đức Trung</b>  |
| <b>Mã sinh viên:</b>         | <b>B23DCCN858</b>        |

## **LỜI CẢM ƠN**

Em xin trân trọng gửi lời cảm ơn đến thầy TS. Kim Ngọc Bách. Thầy đã trực tiếp hướng dẫn, định hướng chuyên môn và tận tình chỉ bảo, đưa ra những giải pháp thiết thực mỗi khi em gặp khó khăn trong suốt quá trình triển khai đề tài. Những lời khuyên của thầy không chỉ giúp em hoàn thành báo cáo đúng tiến độ mà còn giúp em hiểu sâu hơn về quy trình xây dựng một dự án thực tế.

Dù đã dành nhiều thời gian đầu tư và cố gắng hoàn thành tốt nhất các mục tiêu đề ra, nhưng do kinh nghiệm thực tế của bản thân còn hạn chế nên báo cáo và sản phẩm chắc chắn không tránh khỏi những thiếu sót. Em rất mong sẽ nhận được những ý kiến đóng góp, nhận xét và chỉ bảo tận tình từ các thầy cô để em có thể hoàn thiện kiến thức cũng như kỹ năng của mình trong các học phần tiếp theo.

Em xin chân thành cảm ơn!

# MỤC LỤC

|                                                            |          |
|------------------------------------------------------------|----------|
| <b>LỜI CẢM ƠN .....</b>                                    | <b>2</b> |
| <b>CHƯƠNG 1: GIỚI THIỆU .....</b>                          | <b>5</b> |
| 1.1. Bối cảnh .....                                        | 5        |
| 1.2. Đặt vấn đề .....                                      | 5        |
| 1.3. Mục tiêu .....                                        | 6        |
| 1.4. Phạm vi .....                                         | 6        |
| 1.5. Đóng góp.....                                         | 6        |
| <b>CHƯƠNG 2. XÂY DỰNG VÀ FINETUNE MÔ HÌNH ENVIT5 .....</b> | <b>7</b> |
| 2.1. Bài toán Fine-tuning .....                            | 7        |
| 2.2. Chuẩn bị dữ liệu.....                                 | 7        |
| 2.2.1. Giới thiệu bộ dữ liệu MedEV .....                   | 7        |
| 2.2.2. Lựa chọn tập con dữ liệu .....                      | 7        |
| 2.3. Xây dựng tập huấn luyện.....                          | 8        |
| 2.3.1. Cấu trúc dữ liệu trong MedEV .....                  | 8        |
| 2.3.2. Phân chia tập dữ liệu .....                         | 8        |
| 2.3.3. Tiền xử lý và Tokenization.....                     | 9        |
| 2.4. Lựa chọn mô hình nền .....                            | 9        |
| 2.4.1. Giới thiệu EnViT5 .....                             | 9        |
| 2.4.2. Kiến trúc Transformer và cơ chế Attention.....      | 9        |
| 2.5. Thiết kế pipeline huấn luyện .....                    | 10       |
| 2.5.1. Phương pháp LoRA .....                              | 10       |
| 2.5.2. Cấu hình LoRA cho EnViT5 .....                      | 10       |
| 3.6. Cấu hình huấn luyện.....                              | 11       |
| 3.6.1 Training Arguments.....                              | 11       |
| 2.6.2. Môi trường huấn luyện .....                         | 11       |
| 2.7. Đánh giá.....                                         | 11       |
| 2.7.1. Thang đo BLEU.....                                  | 11       |
| 2.8.2. Thang đo TER .....                                  | 12       |
| 2.8.3. Thang đo METEOR.....                                | 12       |
| 2.9. Kết quả thực nghiệm.....                              | 12       |
| 2.10. Phân tích kết quả.....                               | 12       |
| 2.11. Hạn chế .....                                        | 13       |

|                                                                     |           |
|---------------------------------------------------------------------|-----------|
| <b>CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG MEDTRANS .....</b>      | <b>13</b> |
| 3.1. Tổng quan hệ thống MedTrans.....                               | 13        |
| 3.2. Chức năng hệ thống .....                                       | 14        |
| 3.2.1. Nhóm chức năng Dịch thuật .....                              | 14        |
| 3.2.2. Nhóm chức năng Chatbot Y tế .....                            | 15        |
| 3.3. Công nghệ sử dụng .....                                        | 15        |
| 3.4. Tích hợp dịch vụ dịch thuật EnViT5 .....                       | 16        |
| 3.4.1. Triển khai mô hình sau khi fine-tune .....                   | 16        |
| 3.4.2. Cơ chế gọi API và xử lý hướng dịch .....                     | 16        |
| 3.4.3. Đo lường và hiển thị độ trễ.....                             | 17        |
| 3.5. Hệ thống Chatbot Y tế (Medical RAG).....                       | 17        |
| 3.5.1. Giới thiệu và mục đích .....                                 | 17        |
| 3.5.2. Cơ sở tri thức y học .....                                   | 18        |
| 3.5.3. Kiến trúc hệ thống .....                                     | 18        |
| 3.5.4. Thuật toán BM25 trong tìm kiếm văn bản .....                 | 19        |
| 3.5.5. Kết hợp BM25 và Dense Search qua thuật toán RRF Fusion ..... | 20        |
| 3.5.6. Tích hợp mô hình EnViT5 cho xử lý đa ngôn ngữ.....           | 21        |
| 3.5.7. Luồng xử lý RAG Pipeline từ đầu đến cuối .....               | 21        |
| 3.5.8. Nhận xét.....                                                | 22        |
| 3.6. Cơ sở dữ liệu hệ thống.....                                    | 23        |
| <b>CHƯƠNG 4. KẾT LUẬN .....</b>                                     | <b>24</b> |
| 4.1. Tổng kết.....                                                  | 24        |
| 4.2. Đóng góp .....                                                 | 24        |
| <b>THAM KHẢO.....</b>                                               | <b>25</b> |

# CHƯƠNG 1: GIỚI THIỆU

## 1.1. Bối cảnh

Trong bối cảnh toàn cầu hóa và hội nhập quốc tế ngày càng sâu rộng, lĩnh vực y tế Việt Nam đang đối mặt với nhu cầu ngày càng lớn về tiếp cận và xử lý tài liệu y khoa bằng tiếng Anh. Các bác sĩ, nhà nghiên cứu và sinh viên y khoa thường xuyên phải đọc, dịch và nghiên cứu các tài liệu chuyên ngành từ các tạp chí khoa học quốc tế, hướng dẫn điều trị, hồ sơ bệnh án và nghiên cứu lâm sàng. Quá trình này đòi hỏi không chỉ độ chính xác ngôn ngữ mà còn sự hiểu biết sâu về thuật ngữ y khoa chuyên ngành.

Các hệ thống dịch máy đa dụng như Google Translate hay DeepL, mặc dù đã đạt được những tiến bộ đáng kể trong những năm gần đây, vẫn gặp nhiều hạn chế khi xử lý văn bản y khoa. Các thuật ngữ chuyên môn như tên bệnh, tên thuốc, quy trình lâm sàng và khái niệm y sinh học thường bị dịch sai hoặc thiếu chính xác, có thể dẫn đến những hậu quả nghiêm trọng trong môi trường y tế. Đây là lý do chính thúc đẩy hướng nghiên cứu phát triển các hệ thống dịch máy chuyên ngành y khoa.

Trong những năm gần đây, kỹ thuật fine-tuning (tinh chỉnh) các mô hình ngôn ngữ lớn đã nổi lên như một phương pháp hiệu quả để thích nghi hóa các mô hình đã được tiền huấn luyện (pre-trained) cho các miền dữ liệu chuyên biệt. Đặc biệt, với sự ra đời của các kỹ thuật Parameter-Efficient Fine-Tuning (PEFT) như LoRA, việc tinh chỉnh các mô hình lớn đã trở nên khả thi hơn về mặt tài nguyên tính toán.

## 1.2. Đặt vấn đề

Bài toán trọng tâm của dự án này là: làm thế nào để nâng cao chất lượng dịch máy từ tiếng Anh sang tiếng Việt trong lĩnh vực y khoa, đặc biệt đối với các văn bản chứa thuật ngữ y sinh học chuyên sâu? Các hệ thống dịch tổng quát hiện tại gặp phải một số vấn đề cụ thể:

- Thiếu khả năng nhận diện và dịch chính xác thuật ngữ y khoa chuyên ngành, dẫn đến các bản dịch sai nghĩa hoặc mơ hồ.
- Không bảo toàn được cấu trúc câu phức tạp đặc trưng của văn bản y sinh học, nơi một câu có thể chứa nhiều khái niệm liên quan đến nhau.
- Thiếu ngữ cảnh lâm sàng cụ thể, dẫn đến việc các thuật ngữ đa nghĩa được dịch không phù hợp với bối cảnh y tế.

- Không có cơ chế lưu trữ và quản lý lịch sử dịch thuật để người dùng tham chiếu lại.

Để giải quyết những vấn đề trên, dự án đề xuất xây dựng hệ thống MedTrans – một ứng dụng dịch thuật y khoa chuyên biệt, trong đó đóng góp kỹ thuật chính là quá trình fine-tune mô hình EnViT5 trên bộ dữ liệu y sinh học MedEV bằng kỹ thuật LoRA.

### 1.3. Mục tiêu

Dự án hướng đến các mục tiêu cụ thể sau:

- Nghiên cứu và áp dụng kỹ thuật fine-tuning với LoRA để tinh chỉnh mô hình dịch máy EnViT5 trên dữ liệu y sinh học tiếng Anh–Việt.
- Xây dựng và chuẩn bị tập dữ liệu huấn luyện chất lượng cao từ bộ dữ liệu MedEV với 100.000 cặp câu song ngữ.
- Đánh giá toàn diện chất lượng bản dịch trước và sau fine-tuning bằng ba thang đo: BLEU, TER và METEOR.
- Triển khai mô hình đã fine-tune dưới dạng dịch vụ API thông qua FastAPI để tích hợp vào ứng dụng web.
- Xây dựng hệ thống ứng dụng web MedTrans hoàn chỉnh bao gồm frontend React, backend Spring Boot và chatbot RAG y tế.

### 1.4. Phạm vi

Phạm vi của dự án bao gồm: (1) fine-tuning mô hình dịch máy EnViT5 trên dữ liệu y sinh học; (2) xây dựng API inference phục vụ dịch thuật theo hướng Anh→Việt và Việt→Anh; (3) phát triển ứng dụng web MedTrans với đầy đủ chức năng quản lý phiên dịch; (4) tích hợp chatbot RAG y tế sử dụng tìm kiếm Hybrid Retrieval.

Dự án không bao gồm: dịch thuật cho các ngôn ngữ khác ngoài Anh–Việt; xử lý tài liệu dạng hình ảnh hoặc PDF trực tiếp.

### 1.5. Đóng góp

Đóng góp chính của dự án bao gồm: (1) đề xuất và triển khai pipeline fine-tuning hiệu quả cho mô hình dịch máy T5 trên dữ liệu y khoa sử dụng LoRA; (2) cải thiện điểm BLEU từ 40,84 lên 44,18, giảm TER từ 54,43 xuống 51,86 và tăng METEOR từ 0,6491 lên 0,6981; (3) xây dựng hệ thống ứng dụng y tế hoàn chỉnh tích hợp dịch thuật AI và chatbot RAG; (4) đóng góp bộ dữ liệu và mã nguồn fine-tuning phục vụ cộng đồng nghiên cứu.

## CHƯƠNG 2. XÂY DỰNG VÀ FINETUNE MÔ HÌNH ENViT5

### 2.1. Bài toán Fine-tuning

Bài toán fine-tuning trong dự án này thuộc dạng thích nghi miền (domain adaptation) cho hệ thống dịch máy nơ-ron. Cụ thể, mô hình EnViT5 đã được tiền huấn luyện trên dữ liệu song ngữ Anh–Việt tổng quát cần được tinh chỉnh để cải thiện chất lượng dịch trong miền y sinh học.

Hai thách thức kỹ thuật chính cần giải quyết là: (1) hiện tượng catastrophic forgetting – mô hình quên tri thức tổng quát khi học quá chuyên sâu vào miền mới; (2) hạn chế tài nguyên – full fine-tuning mô hình với hàng trăm triệu tham số đòi hỏi VRAM lớn và thời gian huấn luyện dài. Phương pháp LoRA được chọn để giải quyết cả hai thách thức này đồng thời.

### 2.2. Chuẩn bị dữ liệu

#### 2.2.1. Giới thiệu bộ dữ liệu MedEV

Bộ dữ liệu MedEV [1] bao gồm khoảng 360.000 cặp câu song ngữ Anh–Việt trong lĩnh vực y sinh học. Dữ liệu được thu thập từ các nguồn y khoa uy tín bao gồm: tóm tắt bài báo khoa học từ PubMed và các tạp chí y tế, cẩm nang MSD Manuals (ấn bản tiếng Việt), tóm tắt luận án tiến sĩ y khoa, và các bài báo được các bác sĩ dịch thuật. Nội dung bao phủ nhiều chủ đề y khoa như bệnh học, dược học, điều trị lâm sàng và nghiên cứu y sinh.

Đặc điểm nổi bật của MedEV so với các tập dữ liệu tổng quát là tính chuyên biệt cao về miền dữ liệu: dữ liệu chứa phong phú các thuật ngữ y khoa, tên bệnh, tên thuốc và cấu trúc câu học thuật. Điều này giúp mô hình sau fine-tuning có thể tiếp cận các khái niệm y khoa mà dữ liệu tiền huấn luyện tổng quát thường không bao phủ đầy đủ. Theo nghiên cứu gốc của MedEV, fine-tuning các mô hình dịch máy trên tập dữ liệu này mang lại sự cải thiện đáng kể về chất lượng dịch thuật chuyên ngành.

#### 2.2.2. Lựa chọn tập con dữ liệu

Do hạn chế về tài nguyên tính toán (giới hạn thời gian GPU và dung lượng VRAM), quyết định sử dụng tập con 100.000 cặp câu thay vì toàn bộ 360.000 cặp câu của MedEV. Lý do kỹ thuật cho quyết định này: (1) Mô hình EnViT5 đã được tiền huấn luyện trên lượng lớn dữ liệu song ngữ Anh–Việt, nên không cần lượng dữ liệu fine-tuning quá lớn để thích nghi với miền mới; (2) Nhiều nghiên cứu về transfer learning cho thấy fine-

tuning với vài chục nghìn mẫu có thể mang lại cải thiện đáng kể trên mô hình đã được tiền huấn luyện tốt; (3) Kích thước dữ liệu nhỏ hơn cho phép thử nghiệm nhiều cấu hình hyperparameter khác nhau trong thời gian hợp lý.

Việc lựa chọn 100.000 mẫu này được thực hiện theo phương pháp controlled random sampling: dữ liệu được shuffle với seed cố định để đảm bảo tính tái lập kết quả và tránh bias theo từng tiểu miền y khoa (bệnh học, dược học, điều trị...). Phân bố đồng đều giúp mô hình học được các mẫu ngôn ngữ đa dạng của văn bản y khoa.

### 2.3. Xây dựng tập huấn luyện

#### 2.3.1. Cấu trúc dữ liệu trong MedEV

Bộ dữ liệu MedEV có cấu trúc đặc thù: dữ liệu song ngữ được lưu trữ trong một file duy nhất dưới dạng hai nửa riêng biệt – nửa đầu chứa toàn bộ câu tiếng Anh, nửa sau chứa toàn bộ câu tiếng Việt. Do đó, cần sử dụng offset để ghép cặp song ngữ chính xác. Dữ liệu được tải trực tiếp từ HuggingFace bằng thư viện datasets của HuggingFace Transformers.

#### 2.3.2. Phân chia tập dữ liệu

Sau khi lựa chọn 100.000 cặp câu, tập dữ liệu được phân chia thành ba phần theo tỉ lệ 80/10/10:

| Tập dữ liệu    | Số lượng mẫu   | Mục đích                                      |
|----------------|----------------|-----------------------------------------------|
| Train set      | 80.000 cặp câu | Huấn luyện mô hình                            |
| Validation set | 10.000 cặp câu | Theo dõi quá trình huấn luyện, early stopping |
| Test set       | 10.000 cặp câu | Đánh giá cuối cùng, không tham gia huấn luyện |

Tỉ lệ phân chia 80/10/10 đảm bảo mô hình có đủ dữ liệu để học trong khi vẫn có tập validation và test độc lập để đánh giá khách quan. Việc giữ test set hoàn toàn tách biệt khỏi quá trình huấn luyện và lựa chọn mô hình đảm bảo tính trung thực của kết quả đánh giá cuối cùng.



### 2.3.3. Tiền xử lý và Tokenization

Quá trình tiền xử lý dữ liệu bao gồm các bước sau: (1) Ghép cặp song ngữ sử dụng offset từ cấu trúc MedEV; (2) Chuẩn hóa khoảng trắng và ký tự đặc biệt; (3) Lọc các cặp câu có độ dài không cân đối; (4) Tokenization sử dụng AutoTokenizer của mô hình VietAI/envit5-translation với use\_fast=False.

Hàm preprocess\_function được thiết kế theo format text-to-text của T5: câu nguồn tiếng Anh được thêm tiền tố 'en: ', câu đích tiếng Việt được thêm tiền tố 'vi: '. Tokenization được thực hiện với max\_length=512 tokens và truncation=True. Các token padding trong chuỗi nhãn (labels) được thay thế bằng giá trị -100 để bỏ qua khi tính cross-entropy loss trong quá trình huấn luyện.

## 2.4. Lựa chọn mô hình nền

### 2.4.1. Giới thiệu EnViT5

EnViT5 [2] [3] là mô hình dịch máy Anh–Việt được phát triển bởi VietAI, dựa trên kiến trúc T5 (Text-to-Text Transfer Transformer). T5 biểu diễn mọi bài toán NLP dưới dạng bài toán chuyển đổi văn bản sang văn bản, cho phép áp dụng thống nhất cho nhiều nhiệm vụ khác nhau. Mô hình EnViT5 có khoảng 278 triệu tham số và đã được huấn luyện trên tập dữ liệu MTet – bộ dữ liệu đa miền Anh–Việt quy mô lớn bao gồm nhiều lĩnh vực từ tin tức, văn học đến khoa học.

Lý do chọn EnViT5 làm mô hình nền cho dự án: (1) Đây là mô hình đã được tối ưu hóa đặc biệt cho cặp ngôn ngữ Anh–Việt, giúp giảm đáng kể chi phí fine-tuning so với các mô hình đa ngôn ngữ tổng quát; (2) Kiến trúc T5 encoder-decoder phù hợp với bài toán dịch máy seq2seq; (3) Mô hình đã học được nhiều đặc trưng ngôn ngữ học quan trọng của tiếng Việt bao gồm cấu trúc câu, cách biểu đạt ý nghĩa và sự khác biệt trật tự từ; (4) Mô hình có sẵn trên HuggingFace Hub (VietAI/envit5-translation) và dễ dàng tích hợp với thư viện Transformers.

### 2.4.2. Kiến trúc Transformer và cơ chế Attention

EnViT5 kế thừa kiến trúc Transformer [4] với cơ chế self-attention là nền tảng. Khác với các mô hình RNN và LSTM xử lý tuần tự từng token, Transformer cho phép mỗi token trực tiếp xem xét toàn bộ các token khác trong chuỗi thông qua cơ chế self-attention. Cơ chế multi-head attention chồng nhiều self-attention lên nhau, cho phép mô hình học đồng thời nhiều loại quan hệ ngữ nghĩa khác nhau.

Đối với bài toán dịch văn bản y khoa – nơi ý nghĩa của một thuật ngữ phụ thuộc mạnh vào ngữ cảnh xung quanh và các câu thường chứa nhiều khái niệm liên quan – khả năng nắm bắt quan hệ dài hạn và xử lý song song của Transformer mang lại lợi thế rõ rệt so với các kiến trúc trước.

## 2.5. Thiết kế pipeline huấn luyện

### 2.5.1. Phương pháp LoRA

LoRA (Low-Rank Adaptation) [5] là phương pháp fine-tuning hiệu quả về tham số (PEFT), được thiết kế để giảm chi phí tính toán khi tinh chỉnh các mô hình học sâu lớn. Thay vì cập nhật toàn bộ trọng số mô hình, LoRA giữ nguyên các tham số gốc và bổ sung các ma trận có hạng thấp (low-rank matrices) vào các lớp attention.

Về mặt toán học, nếu ma trận trọng số gốc là  $W_0 \in R^{d \times k}$ , LoRA biểu diễn sự thay đổi dưới dạng tích của hai ma trận hạng thấp:

$$\Delta W = B.A$$

Trong đó,  $A \in R^{r \times k}$  và  $B \in R^{d \times r}$  với  $\text{rank } r \ll \min(d, k)$ . Điều này giảm số tham số cần huấn luyện từ  $d \times k$  xuống  $r \times (d + k)$ , giảm đáng kể yêu cầu VRAM và thời gian huấn luyện. Ưu điểm quan trọng của LoRA là giữ nguyên trọng số gốc  $W_0$ , giúp giảm thiểu catastrophic forgetting trong khi vẫn cho phép mô hình thích nghi với miền dữ liệu mới.

### 2.5.2. Cấu hình LoRA cho EnViT5

LoRA được cấu hình để áp dụng vào các lớp attention của mô hình EnViT5, cụ thể là bốn module: query (q), key (k), value (v) và output projection (o). Đây là các lớp chịu trách nhiệm chính trong việc học quan hệ ngữ nghĩa giữa các token, do đó việc fine-tune chỉ các lớp này đã đủ để mô hình thích nghi với miền y khoa.

| Tham số LoRA | Gía trị | Ý nghĩa                                                                     |
|--------------|---------|-----------------------------------------------------------------------------|
| rank (r)     | 16      | Hạng của ma trận low-rank                                                   |
| lora_alpha   | 32      | Hệ số scale ( $\frac{\alpha}{r} = 2$ ); kiểm soát mức độ ảnh hưởng của LoRA |
| Lora_dropout | 0.05    | Dropout để tránh hiện tượng overfitting                                     |

## 3.6. Cấu hình huấn luyện

### 3.6.1 Training Arguments

Quá trình huấn luyện sử dụng Seq2SeqTrainer và Seq2SeqTrainingArguments từ thư viện HuggingFace Transformers. Bảng dưới đây tóm tắt các hyperparameter chính:

| Hyperparameter              | Gía trị | Lý do lựa chọn                                       |
|-----------------------------|---------|------------------------------------------------------|
| per_device_train_batch_size | 8       | Phù hợp với VRAM GPU T4 (16GB) và H100               |
| gradient_accumulation_steps | 4       | Effective batch size = 32; tăng ổn định gradient     |
| learning_rate               | 2e-4    | Học sâu tốt cho LoRA adapter mà không quá lớn        |
| num_train_epochs            | 10      | Đủ để model hội tụ trên 100K mẫu (10h 17m trên H100) |

### 2.6.2. Môi trường huấn luyện

Quá trình huấn luyện được thực hiện trên hai môi trường GPU khác nhau trong các giai đoạn: (1) NVIDIA H100 SXM5 trên Kaggle – được sử dụng cho thử nghiệm 1 epoch và 10 epoch với 100.000 mẫu, cho phép huấn luyện nhanh (thời gian 10 giờ 17 phút cho 10 epoch với 80.000 mẫu); (2) NVIDIA Tesla T4 trên Kaggle – được sử dụng cho triển khai inference service sau huấn luyện, với latency 600–800ms mỗi câu.

## 2.7. Đánh giá

### 2.7.1. Thang đo BLEU

BLEU (Bilingual Evaluation Understudy) [6] là thang đo phổ biến nhất trong đánh giá dịch máy, đo mức độ trùng lặp n-gram giữa bản dịch của mô hình và bản dịch tham chiếu. Công thức tổng quát:

$$BLEU = BP \times \exp\left(\sum_{n=1}^N w_n \log p_n\right)$$

Trong đó  $p_n$  là độ chính xác n-gram,  $w_n$  là trọng số của từng mức n-gram (thường là  $1/N$  cho N-gram BLEU), BP là hệ số phạt độ ngắn (Brevity Penalty) để tránh các bản dịch quá ngắn. Ưu điểm của BLEU là tính toán nhanh, có tương quan tốt với đánh giá con người ở mức corpus. Hạn chế là không đánh giá được ngữ nghĩa sâu và nhạy cảm với cách diễn đạt.

### 2.8.2. Thang đo TER

TER (Translation Edit Rate) [7] đánh giá chất lượng bản dịch dựa trên số lượng thao tác chỉnh sửa cần thiết để biến bản dịch mô hình thành bản dịch tham chiếu, bao gồm: chèn (insertion), xóa (deletion), thay thế (substitution) và hoán đổi vị trí (shift). Công thức:  $TER = (\text{số phép chỉnh sửa}) / (\text{độ dài câu tham chiếu})$ . TER có giá trị càng thấp thì bản dịch càng tốt. Ưu điểm là trực quan, phản ánh chi phí hậu chỉnh sửa. Hạn chế là không đánh giá tính tự nhiên và ngữ nghĩa.

### 2.8.3. Thang đo METEOR

METEOR (Metric for Evaluation of Translation with Explicit ORdering) [8] được đề xuất để cải thiện các hạn chế của BLEU bằng cách kết hợp: (1) khớp chính xác (exact match), khớp từ gốc (stemming) và khớp từ đồng nghĩa (synonym matching) thông qua WordNet; (2) ưu tiên Recall hơn Precision theo công thức  $F_{mean} = \frac{10PR}{R+9P}$ ; (3) hình phạt sắp xếp (ordering penalty) kiểm soát tính liên tục ngữ pháp. METEOR có tương quan cao hơn với đánh giá của con người so với BLEU.

## 2.9. Kết quả thực nghiệm

Kết quả cho thấy mô hình fine-tuned cải thiện đáng kể trên cả ba thang đo đánh giá. Đây là kết quả đánh giá trên tập test độc lập, phản ánh khả năng tổng quát hóa thực sự của mô hình ra ngoài dữ liệu huấn luyện.

| Metric                   | Trước finetune | Sau finetune | Cải thiện |
|--------------------------|----------------|--------------|-----------|
| BLEU (0-100)             | 40,84          | 44,18        | +8,18%    |
| TER (thấp hơn = tốt hơn) | 54,43          | 51,86        | -4,72%    |
| METEOR (0-1)             | 0,6491         | 0,6981       | +7,55%    |

### 2.10. Phân tích kết quả

Kết quả thực nghiệm cho thấy fine-tuning với LoRA trên dữ liệu MedEV mang lại cải thiện nhất quán trên toàn bộ ba thang đo. Điểm BLEU tăng 3,34 điểm tuyệt đối (8,18% tương đối) phản ánh khả năng tạo ra các bản dịch sát với bản tham chiếu hơn về mặt từ vựng và n-gram. Điểm TER giảm 2,57 điểm cho thấy bản dịch sau fine-tuning cần ít chỉnh sửa hơn để đạt được bản dịch chuẩn. Điểm METEOR tăng 0,049 (7,55%) cho thấy cải thiện thực sự về ngữ nghĩa, không chỉ là trùng lặp từ vựng bề mặt.

Điều đặc biệt có ý nghĩa là với chỉ 1 epoch huấn luyện đầu tiên, BLEU đã tăng khoảng 6 điểm (từ 40,84 lên 46,36), cho thấy mô hình đã học nhanh các mẫu ngôn ngữ y khoa từ dữ liệu MedEV. Điều này xác nhận tính hiệu quả của chiến lược fine-tuning với LoRA: mô hình có thể thích nghi với miền dữ liệu mới nhanh chóng nhờ nền tảng ngôn ngữ học đã được học trong giai đoạn tiền huấn luyện.

Xu hướng loss trong quá trình huấn luyện 10 epoch cho thấy training loss giảm đều từ 1.0701 (epoch 1) xuống 0.9009 (epoch 10), validation loss giảm từ 0.9831 xuống 0.9426 nhưng có dấu hiệu tăng nhẹ ở epoch cuối (0.9426 so với 0.9421 ở epoch 9). Điều này cho thấy mô hình bắt đầu overfitting nhẹ sau epoch 9, nhưng BLEU vẫn tiếp tục tăng (48,61  $\rightarrow$  48,64), cho thấy overfitting chưa ảnh hưởng đáng kể đến chất lượng dịch thuật thực tế.

## 2.11. Hạn chế

Dù đạt được kết quả khả quan, dự án còn một số hạn chế đáng ghi nhận:

- Kích thước dữ liệu: Sử dụng 100.000 cặp câu thay vì toàn bộ 360.000 cặp câu MedEV do hạn chế tài nguyên. Việc sử dụng toàn bộ dữ liệu có thể cho kết quả tốt hơn đáng kể.
- Thang đo đánh giá tự động: Ba thang đo BLEU, TER và METEOR đều dựa trên so sánh với bản dịch tham chiếu, không phản ánh hoàn toàn chất lượng dịch thuật từ góc độ người dùng y tế thực tế.
- Đánh giá chuyên gia: Chưa có đánh giá từ các chuyên gia y tế về chất lượng và độ chính xác thuật ngữ trong bản dịch.
- Phạm vi chủ đề: Mô hình được fine-tune trên dữ liệu y sinh học tổng quát, hiệu quả có thể giảm trên các tiểu miền chuyên sâu như hóa trị liệu, phẫu thuật thần kinh hay y học phân tử.
- Triển khai inference: Phụ thuộc vào Kaggle với GPU T4 thông qua ngrok, không phù hợp cho sản xuất thực tế do thiếu tính ổn định và khả năng mở rộng.


## CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG MEDTRANS

### 3.1. Tổng quan hệ thống MedTrans

MedTrans là một ứng dụng web dịch thuật y khoa trực tuyến được xây dựng nhằm hỗ trợ người dùng dịch nhanh và chính xác nội dung chuyên môn giữa tiếng Anh và tiếng Việt. Điểm khác biệt căn bản so với các công cụ dịch phổ thông như Google Translate

hay DeepL nằm ở chỗ MedTrans sử dụng mô hình ngôn ngữ EnViT5 đã được tinh chỉnh chuyên biệt trên dữ liệu y sinh học, giúp xử lý chính xác các thuật ngữ y khoa, tên bệnh, tên thuốc và cấu trúc câu học thuật mà các mô hình tổng quát thường dịch sai hoặc mơ hồ.

Ngoài chức năng dịch thuật, MedTrans còn tích hợp một chatbot y tế hoạt động theo mô hình RAG (Retrieval-Augmented Generation), cho phép người dùng đặt câu hỏi về các vấn đề sức khỏe và nhận câu trả lời có căn cứ từ cơ sở tri thức y học đáng tin cậy. Hai chức năng này hoạt động song song và độc lập với nhau, cùng phục vụ mục tiêu hỗ trợ cộng đồng y tế Việt Nam tiếp cận và xử lý tài liệu chuyên ngành hiệu quả hơn.



Hình 3.1: Tổng quan hệ thống

### 3.2. Chức năng hệ thống

Hệ thống MedTrans cung cấp hai nhóm chức năng chính, được phân biệt rõ ràng với hai loại cuộc hội thoại: Dịch thuật và Chat Y tế.

#### 3.2.1. Nhóm chức năng Dịch thuật

Nhóm chức năng đầu tiên xoay quanh việc dịch văn bản y khoa. Người dùng có thể tạo mới một phiên dịch thuật, nhập văn bản cần dịch và lựa chọn hướng dịch giữa Anh sang Việt hoặc Việt sang Anh. Kết quả dịch được trả về từ mô hình AI và hiển thị ngay trong

giao diện chat, kèm theo chỉ số thời gian phản hồi để người dùng theo dõi độ trễ. Người dùng có thể sao chép kết quả bằng một cú nhấp, xem lại toàn bộ lịch sử các tin nhắn trong phiên và xóa phiên dịch khi không còn cần thiết. Mỗi phiên dịch được đặt tên tự động theo 50 ký tự đầu của lần dịch đầu tiên, giúp dễ nhận biết trong Sidebar.

**3.2.2. Nhóm chức năng Chatbot Y tế**

Nhóm chức năng thứ hai là chatbot hỏi đáp y khoa. Người dùng có thể đặt câu hỏi về các vấn đề sức khỏe bằng tiếng Việt hoặc tiếng Anh mà không cần khai báo ngôn ngữ, hệ thống tự động nhận diện.

**3.3. Công nghệ sử dụng**

Hệ thống MedTrans được xây dựng theo kiến trúc microservice với bốn thành phần kỹ thuật tách biệt, mỗi thành phần lựa chọn công nghệ phù hợp với vai trò của mình.

- Phần giao diện người dùng sử dụng React 18 kết hợp Vite làm công cụ build, TailwindCSS cho thiết kế và hỗ trợ dark mode.
- Phần backend sử dụng Java 17 với Spring Boot 3 làm nền tảng REST API , Spring Data JPA để tương tác với cơ sở dữ liệu, Spring WebFlux WebClient để gọi dịch vụ AI bên ngoài với khả năng xử lý lỗi và thử lại tự động.
- Phần dịch vụ AI Inference sử dụng FastAPI viết bằng Python, thư viện HuggingFace Transformers phiên bản 4.44.0 cùng PEFT để load và chạy mô hình EnViT5 đã tinh chỉnh. Dịch vụ được triển khai trên Kaggle với GPU T4 và sử dụng ngrok để tạo đường dẫn công khai, cho phép backend gọi đến từ môi trường local.
- Phần chatbot RAG sử dụng FastAPI, ChromaDB làm cơ sở dữ liệu vector, thư viện BM25 cho tìm kiếm từ khóa, mô hình nhúng BAAI/bge-m3 cho tìm kiếm ngữ nghĩa, thư viện Lingua để nhận diện ngôn ngữ, và các mô hình ngôn ngữ lớn Google Gemini 2.5 Flash hoặc Alibaba Qwen-Max để sinh câu trả lời. Cơ sở dữ liệu quan hệ MySQL lưu trữ toàn bộ thông tin người dùng, phiên hội thoại và lịch sử tin nhắn.

| Thành phần           | Công nghệ sử dụng                            |
|----------------------|----------------------------------------------|
| Giao diện (Frontend) | React 18, Vite, TailwindCSS, React Router v6 |

| Thành phần           | Công nghệ sử dụng                                                      |
|----------------------|------------------------------------------------------------------------|
| Backend API          | Java 17, Spring Boot 3, Spring Data JPA, Spring WebFlux                |
| AI Inference Service | Python, FastAPI, HuggingFace Transformers 4.44.0, PEFT, PyTorch, ngrok |
| Medical RAG Chatbot  | Python, FastAPI, ChromaDB, BM25, BAAI/bge-m3, Lingua, Gemini / Qwen    |
| Cơ sở dữ liệu        | MySQL                                                                  |

### 3.4. Tích hợp dịch vụ dịch thuật EnViT5

#### 3.4.1. Triển khai mô hình sau khi fine-tune

Sau khi quá trình fine-tuning hoàn tất, mô hình EnViT5 cùng với các trọng số LoRA được merge lại thành một mô hình hoàn chỉnh và lưu trữ trên Kaggle Dataset. Để triển khai mô hình này thành một dịch vụ API có thể gọi từ bên ngoài, dự án sử dụng FastAPI để xây dựng máy chủ inference chạy trực tiếp trên môi trường Kaggle với GPU T4. Vì Kaggle hoạt động trong môi trường mạng nội bộ bị giới hạn, ngrok được tích hợp để đóng vai trò đường hầm kỹ thuật số, ánh xạ cổng dịch vụ nội bộ ra một địa chỉ URL công khai trên internet. Nhờ đó, backend Spring Boot chạy trên máy tính cục bộ có thể gọi đến GPU trên Kaggle mà không bị tường lửa chặn.

Dịch vụ inference cung cấp endpoint chính: endpoint nhận văn bản đầu vào để thực hiện dịch. Hàm inference được cấu hình sử dụng chiến lược beam search với số lượng tia bằng 4 để cân bằng giữa chất lượng dịch và tốc độ phản hồi.

#### 3.4.2. Cơ chế gọi API và xử lý hướng dịch

Backend Spring Boot giao tiếp với dịch vụ FastAPI thông qua giao thức HTTP POST. Khi người dùng gửi yêu cầu dịch, backend nhận được văn bản gốc cùng hướng dịch mà người dùng chọn, sau đó chuẩn hóa đầu vào theo định dạng mà mô hình T5 yêu cầu. Cụ thể, nếu dịch từ tiếng Anh sang tiếng Việt, văn bản được thêm tiền tố ngôn ngữ nguồn trước khi gửi đến dịch vụ; nếu dịch từ tiếng Việt sang tiếng Anh, tiền tố tương ứng của tiếng Việt được sử dụng. Cách thiết kế này xuất phát từ đặc điểm kiến trúc text-to-text của mô hình T5, trong đó tiền tố ngôn ngữ đóng vai trò chỉ thị hướng dịch cho mô hình. Sau khi nhận kết quả từ dịch vụ, backend loại bỏ các tiền tố ngôn ngữ không mong muốn có thể xuất hiện trong output trước khi trả về cho người dùng.




### 3.4.3. Đo lường và hiển thị độ trễ

Độ trễ của mỗi lần dịch được đo chính xác tại tầng gọi dịch vụ AI trong backend. Cụ thể, hệ thống ghi lại thời điểm bắt đầu gửi yêu cầu đến dịch vụ FastAPI và thời điểm nhận được kết quả trả về, hiệu số của hai thời điểm này chính là độ trễ thực tế tính bằng mili giây. Giá trị độ trễ này được lưu vào cơ sở dữ liệu cùng với nội dung tin nhắn và hiển thị trực tiếp trên giao diện người dùng bên cạnh mỗi bản dịch. Qua các lần kiểm thử trên môi trường GPU T4, độ trễ trung bình đạt khoảng 600 đến 800 mili giây cho một câu y tế có độ dài trung bình từ 20 đến 30 từ, đây là mức độ trễ hoàn toàn chấp nhận được đối với một mô hình có khoảng một tỷ tham số. Backend cũng được cấu hình cơ chế thử lại tự động hai lần với độ trễ 500 mili giây giữa mỗi lần, và ngắt kết nối sau 30 giây nếu dịch vụ không phản hồi, đảm bảo hệ thống không bị treo khi dịch vụ AI gặp sự cố.

## 3.5. Hệ thống Chatbot Y tế (Medical RAG)

### 3.5.1. Giới thiệu và mục đích

Chatbot Y tế trong MedTrans là một microservice độc lập được xây dựng theo mô hình RAG (Retrieval-Augmented Generation) [9], tức là kết hợp giữa tìm kiếm thông tin trong cơ sở tri thức và sinh câu trả lời bằng mô hình ngôn ngữ lớn. Mục đích của chatbot là giúp người dùng tra cứu thông tin y tế một cách đáng tin cậy, tránh tình trạng mô hình ngôn ngữ lớn tự bịa đặt thông tin (hallucination) khi trả lời các câu hỏi nhạy cảm liên quan đến sức khỏe. Thay vì để mô hình tự sinh câu trả lời hoàn toàn từ tham số đã học, RAG buộc mô hình phải dựa vào các đoạn tài liệu y khoa đã được xác minh trước khi hình thành câu trả lời, đồng thời trích dẫn nguồn để người dùng có thể kiểm chứng.



Hình 3.2: pipeline thực thi của hệ thống chatbot

### 3.5.2. Cơ sở tri thức y học

Để minh chứng cho khả năng hoạt động của hệ thống, cơ sở tri thức được xây dựng bao gồm tài liệu y khoa về năm nhóm bệnh lý phổ biến: cúm (Influenza), hen suyễn (Asthma), thiếu máu (Anemia), tiểu đường (Diabetes) và tăng huyết áp (Hypertension). Dữ liệu được thu thập tự động từ cổng thông tin y tế Vinmec thông qua công cụ crawl được phát triển riêng cho dự án. Công cụ này hoạt động theo hai chiến lược linh hoạt: chiến lược duyệt theo danh mục bệnh lý từ trang chủ Vinmec, và chiến lược tìm kiếm theo từ khóa cụ thể sử dụng trình duyệt ảo để điều hướng trang. Sau khi thu thập, nội dung HTML được làm sạch để loại bỏ các thành phần không liên quan như menu điều hướng, quảng cáo, thông tin bác sĩ, sau đó được cấu trúc hóa thành tài liệu Markdown và phân chia theo từng nhóm bệnh lý. Cuối cùng, các tài liệu được chia thành các đoạn văn bản nhỏ (chunks) và nạp vào cả ChromaDB lẫn chỉ mục BM25 để phục vụ tìm kiếm.

### 3.5.3. Kiến trúc hệ thống

Chatbot Y tế được thiết kế theo kiến trúc phân tách rõ ràng các tầng chức năng từ ngoài vào trong, đảm bảo logic nghiệp vụ lõi không phụ thuộc vào bất kỳ thư viện hay dịch vụ bên ngoài nào. Bảng dưới đây mô tả từng tầng kiến trúc và vai trò của chúng:

| Tầng kiến trúc              | Thành phần chính                                                     | Chức năng                                                               |
|-----------------------------|----------------------------------------------------------------------|-------------------------------------------------------------------------|
| <b>API Layer</b>            | chat.py   dependencies.py                                            | Tiếp nhận HTTP request, định tuyến                                      |
| <b>Core Layer</b>           | config.py   exceptions.py   logging.py                               | Đọc biến môi trường .env, xử lý lỗi tùy chỉnh, ghi log toàn hệ thống    |
| <b>Domain Layer</b>         | interfaces.py   models.py                                            | Định nghĩa Interfaces/Contracts và Pydantic Models cho Request/Response |
| <b>Infrastructure Layer</b> | embeddings.py   retrievers.py   vectorstore.py   translator.py   llm | Kết nối ChromaDB, mô hình BGE-M3, BM25, EnViT5, Gemini/Qwen             |
| <b>Services Layer</b>       | rag_pipeline.py                                                      | Điều phối toàn bộ vòng đời xử lý RAG                                    |
| <b>Prompts</b>              | medical_prompt.py                                                    | Lưu trữ mẫu System Prompt y tế bằng tiếng Việt và tiếng Anh             |

Thiết kế này mang lại lợi thế quan trọng trong khả năng bảo trì và mở rộng: nếu cần thay thế mô hình LLM từ Gemini sang một nhà cung cấp khác, hoặc chuyển cơ sở dữ liệu vector từ ChromaDB sang Qdrant hay Milvus, chỉ cần thay đổi tầng Infrastructure mà không ảnh hưởng đến logic nghiệp vụ ở tầng Services và Domain. Tầng API sử dụng cơ chế Dependency Injection kết hợp Singleton Pattern để đảm bảo các dịch vụ nặng như mô hình embedding hay vector store chỉ được khởi tạo một lần, tránh tình trạng tràn bộ nhớ khi có nhiều request đồng thời.

#### 3.5.4. Thuật toán BM25 trong tìm kiếm văn bản

BM25 (Best Match 25) [9] là một thuật toán tìm kiếm văn bản dựa trên thống kê xác suất, được phát triển như một cải tiến của mô hình TF-IDF cổ điển. Ý tưởng cốt lõi của BM25 là xếp hạng mức độ liên quan giữa một câu truy vấn và một tài liệu dựa trên hai yếu tố chính: tần suất xuất hiện của từ khóa trong tài liệu và mức độ hiếm của từ khóa đó trong toàn bộ kho tài liệu.

Về cách thức hoạt động, BM25 tính điểm cho mỗi tài liệu bằng cách xét từng từ trong câu truy vấn. Nếu một từ xuất hiện nhiều lần trong tài liệu thì tài liệu đó được điểm cao hơn, nhưng mức tăng điểm sẽ chậm dần để tránh trường hợp một từ lặp đi lặp lại nhiều

lần tạo ra điểm ảo. Đồng thời, BM25 cũng tính đến độ dài tài liệu: một tài liệu ngắn mà chứa nhiều từ khóa được đánh giá tốt hơn một tài liệu dài chứa cùng số từ khóa đó. Yếu tố thứ ba là tần suất nghịch đảo của tài liệu, tức là những từ hiếm gặp trong toàn bộ kho tài liệu sẽ mang trọng số cao hơn những từ phổ biến như giới từ hay liên từ. Điểm mạnh của BM25 nằm ở khả năng khớp chính xác từ khóa, đặc biệt phù hợp với thuật ngữ y khoa chuyên ngành vốn rất đặc thù và hiếm gặp trong văn bản thông thường.

**3.5.5. Kết hợp BM25 và Dense Search qua thuật toán RRF Fusion**

Hệ thống chatbot sử dụng kỹ thuật Hybrid Retrieval, kết hợp hai phương pháp tìm kiếm bổ trợ cho nhau để tối đa hóa khả năng tìm đúng tài liệu liên quan. Phương pháp tìm kiếm dày đặc (Dense Search) sử dụng mô hình nhúng ngôn ngữ BAAI/bge-m3 để chuyển đổi câu hỏi và các đoạn tài liệu thành vector biểu diễn ngữ nghĩa trong không gian nhiều chiều, sau đó tìm những đoạn tài liệu có vector gần nhất với vector câu hỏi. Phương pháp này giải hiểu ý nghĩa tổng thể và xử lý tốt các trường hợp người dùng dùng từ ngữ khác nhau để diễn đạt cùng một ý. Phương pháp tìm kiếm thưa thớt (Sparse Search) sử dụng BM25 để khớp chính xác từ khóa, đặc biệt mạnh khi câu hỏi chứa thuật ngữ y khoa cụ thể như tên bệnh, tên thuốc hoặc tên thủ thuật.

Để hợp nhất kết quả từ hai nguồn này, hệ thống áp dụng thuật toán Reciprocal Rank Fusion (RRF) [10]. Thuật toán này hoạt động bằng cách gán điểm cho mỗi tài liệu dựa trên vị trí xếp hạng của nó trong mỗi danh sách kết quả: tài liệu đứng vị trí thứ k trong danh sách sẽ nhận điểm bằng 1 chia cho tổng của một hằng số cộng với k. Điểm từ hai danh sách được cộng lại cho mỗi tài liệu, sau đó sắp xếp lại theo tổng điểm giảm dần. Cách tiếp cận này đơn giản nhưng hiệu quả: một tài liệu đứng cao trong cả hai danh sách sẽ được điểm tổng rất cao, trong khi một tài liệu chỉ xuất hiện ở một danh sách sẽ được điểm thấp hơn. Cuối cùng, hệ thống trích xuất tối đa bốn đoạn tài liệu có điểm tổng cao nhất để đưa vào ngữ cảnh cho mô hình ngôn ngữ sinh câu trả lời.

| Phương pháp  | Công nghệ         | Điểm mạnh                                               | Điểm yếu                                      |
|--------------|-------------------|---------------------------------------------------------|-----------------------------------------------|
| Dense Search | ChromaDB + BGE-M3 | Hiệu ngữ nghĩa, xử lý từ đồng nghĩa, diễn đạt khác nhau | Có thể bỏ sót tài liệu chứa đúng từ khóa hiếm |

| Phương pháp   | Công nghệ  | Điểm mạnh                                                   | Điểm yếu                                             |
|---------------|------------|-------------------------------------------------------------|------------------------------------------------------|
| Sparse Search | BM25       | Khớp chính xác thuật ngữ chuyên ngành, nhanh, không cần GPU | Không hiểu được ngữ nghĩa, nhạy cảm với cách viết từ |
| Hybrid RRF    | RRF Fusion | Kết hợp điểm mạnh của cả hai, ổn định và toàn diện hơn      | Phức tạp hơn, cần duy trì hai chỉ mục song song      |

### 3.5.6. Tích hợp mô hình EnViT5 cho xử lý đa ngôn ngữ

Cơ sở tri thức của chatbot được lưu trữ hoàn toàn bằng tiếng Việt. Do đó, khi người dùng đặt câu hỏi bằng tiếng Anh, hệ thống cần dịch câu hỏi sang tiếng Việt trước khi thực hiện tìm kiếm để đảm bảo tìm được tài liệu liên quan. Đây chính là nơi mô hình EnViT5 đã fine-tune được tận dụng lần thứ hai trong hệ thống.

Để nhận biết ngôn ngữ đầu vào, hệ thống sử dụng thư viện Lingua, một công cụ nhận diện ngôn ngữ tự nhiên hỗ trợ nhiều ngôn ngữ với độ chính xác cao cho các văn bản ngắn. Thư viện này phân tích đặc điểm thống kê của văn bản đầu vào để xác định ngôn ngữ mà không cần kết nối internet hay gọi API bên ngoài, giúp giảm độ trễ và đảm bảo tính ổn định. Khi hệ thống phát hiện câu hỏi bằng tiếng Anh, câu hỏi đó được gửi đến dịch vụ EnViT5 để dịch sang tiếng Việt, rồi mới thực hiện bước tìm kiếm Hybrid Retrieval. Toàn bộ quá trình này được thực hiện tự động, người dùng không cần khai báo ngôn ngữ hay thực hiện bất kỳ thao tác thêm nào. Câu trả lời cuối cùng được sinh bằng ngôn ngữ gốc của câu hỏi, tức là nếu hỏi tiếng Anh thì nhận câu trả lời tiếng Anh, hỏi tiếng Việt thì nhận tiếng Việt, dựa trên hai bộ System Prompt khác nhau được chuẩn bị sẵn cho mô hình ngôn ngữ lớn.

### 3.5.7. Luồng xử lý RAG Pipeline từ đầu đến cuối

Bảng dưới đây mô tả chi tiết từng bước trong luồng xử lý của RAG Pipeline khi nhận được một câu hỏi từ người dùng:

| # | Bước xử lý                | Mô tả chi tiết                                                  |
|---|---------------------------|-----------------------------------------------------------------|
| 1 | <b>Tiếp nhận câu hỏi</b>  | Nhận ChatRequest qua endpoint /api/v1/chat                      |
| 2 | <b>Nhận diện ngôn ngữ</b> | Thư viện Lingua tự động phát hiện ngôn ngữ đầu vào (vi hoặc en) |

| #  | Bước xử lý                     | Mô tả chi tiết                                                                   |
|----|--------------------------------|----------------------------------------------------------------------------------|
| 3  | <b>Dịch truy vấn (nếu cần)</b> | Nếu câu hỏi là tiếng Anh, mô hình EnViT5 dịch sang tiếng Việt trước khi tìm kiếm |
| 4  | <b>Dense Search</b>            | ChromaDB + mô hình BGE-M3 tìm kiếm theo ngữ nghĩa trong không gian vector        |
| 5  | <b>Sparse Search</b>           | BM25 khớp chính xác từ khóa trên chỉ mục văn bản thô                             |
| 6  | <b>RRF Fusion</b>              | Thuật toán Reciprocal Rank Fusion hợp nhất và xếp hạng kết quả từ hai nguồn      |
| 7  | <b>Trích xuất ngữ cảnh</b>     | Lấy tối đa 4 đoạn tài liệu và metadata nguồn phù hợp nhất                        |
| 8  | <b>Lựa chọn Prompt</b>         | Chọn System Prompt tiếng Việt hoặc tiếng Anh tương ứng ngôn ngữ gốc              |
| 9  | <b>Sinh câu trả lời</b>        | Gửi ngữ cảnh + câu hỏi đến LLM (Gemini 2.5 Flash / Qwen-Max)                     |
| 10 | <b>Trả về kết quả</b>          | ChatResponse                                                                     |

### 3.5.8. Nhận xét

Nhìn lại thiết kế tổng thể của chatbot RAG, có thể nhận thấy hai điểm sáng kỹ thuật quan trọng mang lại giá trị thực sự cho người dùng.

Điểm sáng thứ nhất là việc tích hợp mô hình EnViT5 đã fine-tune vào quy trình tìm kiếm. Đây không chỉ là chi tiết nhỏ mà là yếu tố then chốt quyết định chất lượng tìm kiếm trong một hệ thống RAG tiếng Việt. Nếu câu hỏi tiếng Anh không được dịch sang tiếng Việt trước khi tìm kiếm, cả Dense Search lẫn BM25 đều sẽ thất bại vì toàn bộ cơ sở tri thức được lưu bằng tiếng Việt. Bằng cách sử dụng mô hình đã được tinh chỉnh trên dữ liệu y sinh học, bản dịch câu hỏi giữ được chính xác các thuật ngữ y khoa, giúp tìm kiếm ra đúng tài liệu liên quan thay vì các bản dịch tổng quát kém chính xác.

Điểm sáng thứ hai là cơ chế BM25 trong Hybrid Retrieval. Trong lĩnh vực y khoa, thuật ngữ chuyên ngành như tên bệnh, tên thuốc, hay ký hiệu lâm sàng là những từ cực kỳ đặc thù và hiếm gặp. Tìm kiếm ngữ nghĩa (Dense Search) đôi khi trả về các tài liệu liên quan về mặt chủ đề nhưng không chứa đúng thuật ngữ mà người dùng cần. BM25 bổ sung khả năng khớp chính xác những từ này, đảm bảo hệ thống không bỏ sót tài liệu chứa đúng thông tin dù được viết theo cách khác với vector đã học. Sự kết hợp qua RRF

Fusion tạo ra một hệ thống tìm kiếm vừa hiểu ngữ nghĩa vừa chính xác về từ khóa, điều mà một trong hai phương pháp đơn lẻ không thể đạt được.

### 3.6. Cơ sở dữ liệu hệ thống

Hệ thống MedTrans sử dụng MySQL 8 làm cơ sở dữ liệu quan hệ, tổ chức thành ba bảng chính có quan hệ với nhau thông qua khóa ngoại.

Bảng người dùng lưu trữ thông tin định danh và quyền truy cập của từng tài khoản, bao gồm mã định danh duy nhất, tên đăng nhập, địa chỉ email, mật khẩu đã được mã hóa, vai trò người dùng và thời điểm tạo tài khoản. Mỗi người dùng được đảm bảo tính duy nhất trên cả tên đăng nhập lẫn địa chỉ email.

Bảng phiên hội thoại lưu trữ từng cuộc hội thoại mà người dùng tạo ra. Mỗi phiên có mã định danh, liên kết đến người dùng sở hữu, tiêu đề phiên (tự động cập nhật từ nội dung dịch đầu tiên), loại phiên phân biệt giữa dịch thuật và chatbot, và thời điểm tạo. Khi người dùng bị xóa, toàn bộ phiên hội thoại liên quan sẽ được xóa theo nhờ cơ chế xóa tầng.

Bảng tin nhắn lưu trữ chi tiết từng tin nhắn trong một phiên hội thoại, bao gồm mã định danh, liên kết đến phiên chứa nó, loại người gửi phân biệt giữa người dùng và AI, văn bản gốc, văn bản đã dịch hoặc câu trả lời, độ trễ tính bằng mili giây cho mỗi lần AI phản hồi, loại tin nhắn tương ứng với loại phiên và thời điểm tạo.

| Bảng          | Thông tin lưu trữ chính                                                                                                      |
|---------------|------------------------------------------------------------------------------------------------------------------------------|
| users         | Mã, tên đăng nhập, email, mật khẩu đã mã hóa, vai trò, thời điểm tạo                                                         |
| conversations | Mã, liên kết người dùng, tiêu đề, loại phiên (TRANSLATION / CHATBOT), thời điểm tạo                                          |
| messages      | Mã, liên kết phiên, loại người gửi (USER / AI), văn bản gốc, bản dịch/câu trả lời, độ trễ (ms), loại tin nhắn, thời điểm tạo |

Thiết kế cơ sở dữ liệu áp dụng xóa tầng tự động (CASCADE DELETE) để đảm bảo tính toàn vẹn dữ liệu: khi xóa một phiên hội thoại, toàn bộ tin nhắn trong phiên đó cũng được xóa theo; khi xóa người dùng, toàn bộ phiên và tin nhắn liên quan cũng được dọn sạch. Trường loại phiên và loại tin nhắn được thiết kế như kiểu liệt kê (ENUM) với giá trị

mặc định là TRANSLATION, đảm bảo tương thích ngược với toàn bộ dữ liệu cũ khi chức năng chatbot được thêm vào ở giai đoạn sau.

## **CHƯƠNG 4. KẾT LUẬN**

### **4.1. Tổng kết**

Dự án đã thực hiện thành công việc fine-tuning mô hình dịch máy nơ-ron EnViT5 cho văn bản chuyên ngành y khoa Anh–Việt, đồng thời tích hợp mô hình này vào một hệ thống ứng dụng y tế hoàn chỉnh tên MedTrans. Qua 15 tuần thực hiện, dự án đã trải qua đầy đủ vòng đời phát triển phần mềm từ nghiên cứu lý thuyết, chuẩn bị dữ liệu, xây dựng pipeline huấn luyện, thực nghiệm đến triển khai hệ thống.

Về mặt kỹ thuật AI, phương pháp LoRA với chỉ 1,27% tham số có thể huấn luyện đã chứng minh tính hiệu quả trong việc thích nghi hóa mô hình dịch máy với miền y sinh học, đạt được cải thiện có ý nghĩa trên cả ba thang đo BLEU (+8,18%), TER (-4,72%) và METEOR (+7,55%). Về mặt phần mềm, hệ thống MedTrans đã xây dựng thành công kiến trúc microservice tích hợp dịch thuật AI và chatbot RAG, với giao diện người dùng hiện đại và trải nghiệm sử dụng tốt.

### **4.2. Đóng góp**

Các đóng góp chính của dự án bao gồm:

- Nghiên cứu và triển khai thực tế pipeline fine-tuning EnViT5 với LoRA cho lĩnh vực dịch thuật y khoa, cung cấp bằng chứng thực nghiệm về hiệu quả của PEFT trong domain adaptation cho NMT.
- Xây dựng hệ thống đánh giá toàn diện với ba metric (BLEU, TER, METEOR) và phân tích chi tiết kết quả trên tập test độc lập, cung cấp baseline rõ ràng cho các nghiên cứu tiếp theo.
- Phát triển Medical RAG Chatbot với Hybrid Retrieval (ChromaDB + BM25 + RRF Fusion) hỗ trợ đa ngôn ngữ, đây là đóng góp mới vượt ngoài phạm vi bài toán dịch thuật thuần túy.
- Xây dựng hệ thống ứng dụng y tế end-to-end hoàn chỉnh (React + Spring Boot + FastAPI + MySQL) với kiến trúc microservice có thể mở rộng, phục vụ như một mẫu cho các dự án tương tự.



## THAM KHẢO

- [1] N. Vo, D. Q. Nguyen, D. D. Le, M. Piccardi and W. Buntine, "Improving Vietnamese-English Medical Machine Translation," in *LREC-COLING 2024*, 2024, Proceedings of the Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024).
- [2] C. Ngo, T. H. Trinh, L. Phan, H. Tran, T. Dang, H. Nguyen, M. Nguyen and M.-T. Luong, "EnViT5: English–Vietnamese Translation Model," March 2022. [Online]. Available: <https://huggingface.co/VietAI/envit5-translation>.
- [3] C. Ngo, T. H. Trinh, L. Phan, H. Tran, T. Dang, H. Nguyen, M. Nguyen and M.-T. Luong, "MTet: Multi-domain Translation for English and Vietnamese," no. <https://arxiv.org/abs/2210.05610>, 2022.
- [4] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser and I. Polosukhin, "Attention Is All You Need," in *NeurIPS 2017*, Long Beach, 2017.
- [5] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang and W. Chen, "LoRA: Low-Rank Adaptation of Large Language Models," in *ICLR 2022*, Online, 2022.
- [6] K. Papineni, S. Roukos, T. Ward and W.-J. Zhu, "BLEU: a Method for Automatic Evaluation of Machine Translation," in *ACL 2002*, Philadelphia, 2002.
- [7] M. Snover, B. Dorr, R. Schwartz, L. Micciulla and J. Makhoul, "A Study of Translation Edit Rate with Targeted Human Annotation," in *AMTA 2006*, Cambridge, 2006.
- [8] S. Banerjee and A. Lavie, "METEOR: An Automatic Metric for MT Evaluation with Improved Correlation with Human Judgments," in *ACL Workshop 2005*, Ann Arbor, 2005.
- [9] S. E. R. a. H. Zaragoza, "The Probabilistic Relevance Framework: BM25 and Beyond," *Foundations and Trends in Information Retrieval*, vol. vol. 3, no. no. 4, p. pp. 333–389, 2009.
- [10] G. V. Cormack, C. L. A. Clarke and S. Buettcher, "Reciprocal Rank Fusion outperforms LTR and Individual Information Retrieval Methods," in *SIGIR 2009*, Boston, 2009.

