

Fine-tune mô hình dịch y khoa — MedTrans

Báo cáo thực tập cơ sở: Fine-tune mô hình dịch máy Nơ-ron cho văn bản y khoa Anh-Việt và ứng dụng trên hệ thống MedTrans.

SV: Nguyễn Đức Trung • **GVHD:** TS. Kim Ngọc Bách



Bối cảnh & Đặt vấn đề

Y tế Việt Nam cần dịch chính xác tài liệu y khoa Anh — hướng dẫn, nghiên cứu, hồ sơ bệnh án — đòi hỏi hiểu biết sâu về thuật ngữ chuyên ngành.

Dịch máy phổ thông (Google, DeepL) vẫn mắc lỗi: thuật ngữ sai, mất cấu trúc câu phức tạp, thiếu ngữ cảnh lâm sàng.

Giải pháp đề xuất: xây dựng hệ thống chuyên ngành MedTrans, với nhân tố kỹ thuật chính là fine-tune EnViT5 trên dữ liệu y sinh bằng LoRA.



Mục tiêu chính

Nâng cao chất lượng dịch

Fine-tune EnViT5 bằng kỹ thuật LoRA để cải thiện dịch Anh→Việt trong y khoa.

Đánh giá



So sánh trước/sau fine-tuning bằng BLEU, TER và METEOR.

Chuẩn bị dữ liệu

Tập MedEV: 100.000 cặp câu song ngữ chất lượng cao cho huấn luyện.

Triển khai & Ứng dụng

API inference (FastAPI) và ứng dụng web MedTrans (React + Spring Boot) kèm chatbot RAG y tế.




Phạm vi dự án

Phạm vi bao gồm:

- Fine-tuning EnViT5 trên dữ liệu y sinh học.
- Xây dựng API phục vụ dịch Anh↔Việt.
- Phát triển MedTrans: frontend React, backend Spring Boot.
- Tích hợp chatbot RAG với Hybrid Retrieval.




Không bao gồm: ngôn ngữ ngoài Anh-Việt;
xử lý hình ảnh/PDF trực tiếp.



Xây dựng và Finetune mô hình EnViT5

Tổng quan: Mục tiêu là tinh chỉnh EnViT5 cho dịch Anh-Việt chuyên ngành y sinh, dùng LoRA để giảm chi phí tính toán và tránh catastrophic forgetting.



Bài toán Fine-tuning

Thích nghi miễn

Tinh chỉnh mô hình tiền huấn luyện tổng quát để cải thiện dịch trong miền y sinh.

Thách thức chính


Catastrophic forgetting và hạn chế tài nguyên khi fine-tune toàn bộ tham số.

Giải pháp

Sử dụng LoRA (PEFT) để cập nhật ma trận hạng thấp, giữ nguyên tham số gốc.



Chuẩn bị dữ liệu — MedEV



Bộ dữ liệu MedEV

~360,000 cặp câu Anh-Việt từ PubMed, MSD Manuals, luận án, và bản dịch của bác sĩ — rất chuyên biệt về thuật ngữ y khoa.

Ưu điểm: bao phủ tên bệnh, thuốc, cấu trúc câu học thuật — cải thiện dịch chuyên ngành khi fine-tune.

Xây dựng tập huấn luyện

Chọn 100,000 cặp câu và phân chia 80/10/10 để đảm bảo huấn luyện, validation và test độc lập.

Train


80,000 cặp – huấn luyện mô hình

Validation


10,000 cặp – theo dõi, early
stopping

Test

10,000 cặp – đánh giá cuối, không tham gia huấn luyện



Lựa chọn mô hình nền: EnViT5



EnViT5 (~278M tham số) dựa trên kiến trúc T5, tiền huấn luyện trên MTet đa miền. Lý do chọn:

- Đã tối ưu cho cặp Anh-Việt → giảm chi phí fine-tuning
- Kiến trúc encoder-decoder phù hợp cho seq2seq
- Hiểu các đặc trưng ngôn ngữ tiếng Việt (trật tự, biểu đạt)
- Có sẵn trên HuggingFace (VietAI/envit5-translation)

Thiết kế pipeline huấn luyện — LoRA



Apply LoRA


Train on
MedEV

Evaluate

LoRA: chèn ma trận hạng thấp vào attention, cập nhật ít tham số, tiết kiệm VRAM và thời gian huấn luyện.

Tác dụng: giảm nguy cơ quên tri thức tổng quát và cho phép fine-tune hiệu quả trên GPU giới hạn.

Môi trường huấn luyện & triển khai



Huấn luyện (H100)

Thử nghiệm 1 và 10 epoch trên 100k mẫu. 10 epoch với 80k mẫu mất 10 giờ 17 phút.



Inference (T4)

Triển khai inference trên T4 (Kaggle) — latency ~600–800ms/câu; dùng ngrok cho dịch vụ thử nghiệm, không phù hợp sản xuất.

Đánh giá — Metrics

BLEU


Đo trùng lặp n-gram giữa bản dịch và tham chiếu.

TER


Translation Edit Rate — tỉ lệ thao tác chỉnh sửa (thấp hơn = tốt hơn).

METEOR


Kết hợp exact match, stemming, synonym; ưu tiên recall và kiểm soát ordering penalty.



Kết quả thực nghiệm



Ghi chú: Cải thiện BLEU +3.34 điểm ($\approx +8.18\%$), TER giảm -2.57 điểm, METEOR tăng +0.049 ($\approx +7.55\%$).



Phân tích & Hạn chế

Phân tích


LoRA trên MedEV mang lại cải thiện nhất quán; 1 epoch đầu đã tăng BLEU ~6 điểm cho thấy học nhanh mẫu y khoa.

Hạn chế

- Dùng 100k thay vì 360k do tài nguyên;
- Metrics tự động không phản ánh hoàn toàn chất lượng cho người dùng y tế;
- Thiếu đánh giá chuyên gia;

Định hướng phát triển

Mở rộng dữ liệu, tối ưu pipeline inference cho môi trường thực tiễn.



MedTrans — Tổng quan hệ thống

MedTrans là ứng dụng web dịch thuật y khoa Anh-Việt, dùng EnViT5 fine-tuned cho thuật ngữ y sinh. Kèm chatbot y tế theo mô hình RAG để trả lời câu hỏi dựa trên nguồn tài liệu xác thực.

Điểm khác biệt chính

EnViT5 tinh chỉnh


Mô hình chuyên biệt cho y sinh, giảm lỗi dịch thuật thuật ngữ và cấu trúc học thuật.

Chatbot RAG


Kết hợp retrieval + generation, trích dẫn nguồn để hạn chế hallucination.

Hai chức năng độc lập

Dịch thuật và Chat Y tế hoạt động song song, phục vụ nhu cầu khác nhau của người dùng.



Nhóm chức năng: Dịch thuật




Người dùng tạo phiên dịch, nhập văn bản, chọn hướng (EN→VI hoặc VI→EN). Kết quả hiển thị trong chat, có thời gian phản hồi. Sao chép, xem lịch sử, xóa phiên đều được hỗ trợ. Tên phiên tự động lấy 50 ký tự đầu để nhận diện.

Nhóm chức năng: Chatbot Y tế




Chatbot RAG cho phép hỏi đáp y khoa bằng tiếng Việt/Anh. Hệ thống tự nhận diện ngôn ngữ, tra cứu cơ sở tri thức, và sinh câu trả lời.



Triển khai EnViT5 — Kiến trúc inference

EnViT5 + trọng số LoRA được merge và lưu trên Kaggle Dataset. FastAPI chạy trên GPU T4 (Kaggle), dùng ngrok làm tunnel để backend Spring Boot cục bộ gọi API inference công khai.



Chi tiết gọi API & tiền tố ngôn ngữ


1. Backend Spring Boot gửi HTTP POST tới FastAPI.
2. Chuẩn hóa đầu vào theo định dạng T5: thêm tiền tố ngôn ngữ (EN→VI hoặc VI→EN).
3. Backend loại bỏ tiền tố không mong muốn từ output trước khi trả về người dùng.

Medical RAG — Cơ sở tri thức

Kho dữ liệu lưu bằng tiếng Việt, gồm tài liệu về Influenza, Asthma, Anemia, Diabetes và Hypertension. Dữ liệu crawl từ Vinmec, làm sạch HTML → Markdown → chia thành chunks, nạp vào ChromaDB và chỉ mục BM25.



HYBRID SEARCHES



Chiến lược tìm kiếm: Dense / Sparse / Hybrid



Dense Search

ChromaDB + BGE-M3: hiểu ngữ nghĩa, xử lý đồng nghĩa; rủi ro bỏ sót từ khóa hiếm.



Sparse Search

BM25: khớp chính xác thuật ngữ, nhanh, không cần GPU; không hiểu ngữ nghĩa.




Hybrid RRF

RRF Fusion kết hợp hai nguồn để ổn định và toàn diện hơn, nhưng phức tạp hơn.

SƠ ĐỒ TỔNG QUAN HỆ THỐNG

DỊCH & CHATBOT (HYBRID RAG)





Kết luận & đóng góp

Tổng kết

Hoàn thành fine-tune EnViT5 cho y khoa và tích hợp vào MedTrans; dự án thực hiện trong 15 tuần, đầy đủ vòng đời phát triển.

Đóng góp AI

LoRA (1,27% tham số) cải thiện BLEU +8,18%, TER -4,72%, METEOR +7,55% — bằng chứng hiệu quả PEFT cho domain adaptation.

THANK YOU

● FOR YOUR NICE ATTENTION