

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN



THỰC TẬP CƠ SỞ

BÁO CÁO TUẦN

**Đề tài: Finetune mô hình dịch máy Neural cho
văn bản chuyên ngành y khoa Anh-Việt**

Lớp tín chỉ:	D23CQCN04-B
Giảng viên hướng dẫn:	TS. Kim Ngọc Bách
Sinh viên thực hiện:	Nguyễn Đức Trung
Mã sinh viên:	B23DCCN858

MỤC LỤC

I. MỤC TIÊU CỦA TUẦN LÀM VIỆC	2
1. Mục tiêu tuần làm việc	2
2. Nội dung đã thực hiện	2
3. Kết quả đạt được	2

I. MỤC TIÊU CỦA TUẦN LÀM VIỆC

1. Mục tiêu tuần làm việc

Mục tiêu trọng tâm của giai đoạn này là xây dựng và tối ưu hóa môi trường thực thi (inference) cho mô hình ngôn ngữ lớn EnViT5 đã được tinh chỉnh bằng kỹ thuật LoRA. Thay vì chỉ chạy kiểm tra trên các đoạn mã rời rạc, mục tiêu là biến mô hình thành một dịch vụ (service) có khả năng hoạt động ổn định và sẵn sàng tiếp nhận yêu cầu từ bên ngoài. Điểm cốt lõi là phải tận dụng được tài nguyên phần cứng mạnh mẽ (GPU T4 x2 hoặc P100) trên nền tảng Kaggle để đảm bảo tốc độ phản hồi nhanh nhất cho các tác vụ dịch thuật y tế chuyên sâu, đồng thời tạo ra một giao thức kết nối linh hoạt để chuẩn bị cho việc tích hợp vào ứng dụng web trong giai đoạn kế tiếp.

Với những gì tìm hiểu ở tuần trước, tuần này em quyết định chọn cách thực hiện sau.

2. Nội dung đã thực hiện

Quá trình triển khai bắt đầu bằng việc thiết lập môi trường lập trình Python, bao gồm cài đặt các thư viện hỗ trợ như FastAPI để tạo khung máy chủ, PEFT để quản lý các tham số LoRA và các bộ thư viện tính toán đồ họa từ HuggingFace. Sau khi chuẩn bị môi trường, hệ thống tiến hành nạp cấu trúc mô hình gốc EnViT5 kết hợp với các trọng số tinh chỉnh (weights) được lưu trữ từ quá trình huấn luyện trước đó.

Một bước tiến quan trọng trong nội dung thực hiện là việc nhúng công cụ **ngrok** vào quy trình. Do Kaggle hoạt động trong một môi trường mạng nội bộ bị giới hạn, ngrok đóng vai trò như một "đường hầm" kỹ thuật số, ánh xạ cổng dịch vụ nội bộ tại Kaggle ra một địa chỉ URL công khai. Điều này cho phép máy tính cá nhân hoặc các máy chủ từ xa có thể gửi dữ liệu tới GPU của Kaggle để xử lý mà không bị chặn bởi tường lửa. Đồng thời, cấu hình máy chủ FastAPI cũng được thiết kế để hỗ trợ đa dạng các đầu vào, từ văn bản đơn lẻ đến xử lý hàng loạt (batch inference), giúp tối ưu hóa hiệu suất khi có nhiều yêu cầu cùng lúc.

3. Kết quả đạt được

Kết quả quan trọng nhất là việc lên ý tưởng cho việc thiết lập thành công cơ chế kết nối xuyên suốt: dữ liệu được gửi từ môi trường local thông qua đường truyền ngrok đã đến được server tại Kaggle và trả về kết quả định dạng JSON chuẩn hóa. Đây là nền tảng then chốt để trong tuần làm việc tiếp theo, chúng ta chỉ cần tập trung vào việc xây dựng giao diện người dùng.

