

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN



THỰC TẬP CƠ SỞ

BÁO CÁO TUẦN

**Đề tài: Finetune mô hình dịch máy Neural cho
văn bản chuyên ngành y khoa Anh-Việt**

Lớp tín chỉ:	D23CQCN04-B
Giảng viên hướng dẫn:	TS. Kim Ngọc Bách
Sinh viên thực hiện:	Nguyễn Đức Trung
Mã sinh viên:	B23DCCN858

Hà Nội 2026

MỤC LỤC

I. MỤC TIÊU CỦA TUẦN LÀM VIỆC	2
1. Mục tiêu tuần làm việc	2
2. Nội dung đã thực hiện	2
3. Kết quả đạt được	3

I. MỤC TIÊU CỦA TUẦN LÀM VIỆC

1. Mục tiêu tuần làm việc

Mục tiêu chính của tuần 11 là **triển khai hoàn chỉnh và đưa vào hoạt động** môi trường inference cho mô hình EnViT5 đã tinh chỉnh bằng LoRA. Cụ thể:

- Xây dựng thành công một **FastAPI service** chạy ổn định trên Kaggle (sử dụng GPU T4).
- Tích hợp ngrok để expose public URL, cho phép gọi API từ máy local hoặc các ứng dụng bên ngoài.
- Đảm bảo mô hình hoạt động mượt mà với cả hai chiều dịch En↔Vi trong lĩnh vực y tế.
- Kiểm tra và xác nhận tính ổn định, tốc độ phản hồi, cũng như khả năng xử lý batch inference.

2. Nội dung đã thực hiện

Tuần này tập trung vào việc hiện thực hóa ý tưởng đã lập kế hoạch ở tuần trước. Các công việc chính bao gồm:

- **Chuẩn bị môi trường:** Cài đặt và cấu hình các thư viện cần thiết (transformers==4.44.0, peft, FastAPI, pyngrok, bitsandbytes...).
- **Load & Merge model:** Tải base model VietAI/envit5-translation, merge thành công trọng số LoRA từ dataset trên Kaggle.
- **Xây dựng FastAPI service:**
 - Thiết kế các endpoint: /health, /predict (single), /predict/batch.
 - Sử dụng Pydantic để validate input/output.
 - Thêm CORS middleware để dễ dàng gọi từ frontend sau này.
- **Tích hợp ngrok:** Tạo public URL ổn định để tunnel từ server Kaggle ra ngoài.
- **Triển khai inference function:** Tối ưu hàm run_inference với beam search, hỗ trợ cấu hình max_new_tokens, num_beams, length_penalty.
- **Testing toàn diện:**
 - Test trực tiếp trong notebook.
 - Test qua public URL từ local (cả EN→VI và VI→EN).
 - Kiểm tra latency và tính chính xác trên các câu y tế chuyên sâu.

Toàn bộ quy trình được đóng gói gọn trong notebook `deploy-envit5.ipynb`, dễ dàng chạy lại và duy trì.

3. Kết quả đạt được

- **Hoàn thành 100% mục tiêu đề ra:** Đã có một inference service chạy ổn định trên Kaggle với GPU.
- Public URL hoạt động tốt (ví dụ: <https://subplot-strep-ragweed.ngrok-free.dev> – sẽ thay đổi mỗi lần restart).
- Service hỗ trợ cả single và batch prediction, trả về JSON có thông tin latency.
- Latency trung bình khoảng **600-800ms** cho một câu y tế trung bình (rất tốt với mô hình ~1B parameters trên T4).
- Model merge LoRA thành công và cho kết quả dịch chính xác cao trên dữ liệu y tế.
- Đã chuẩn bị đầy đủ tài liệu hướng dẫn sử dụng (cách gọi API từ local bằng Python hoặc curl).

Nền tảng then chốt cho tuần sau đã sẵn sàng: chỉ cần xây dựng giao diện web (frontend) để kết nối với API này.