HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN

THỰC TẬP CƠ SỞ

BÁO CÁO TUẦN

Đề tài: Finetune mô hình dịch máy Neural cho văn bản chuyên ngành y khoa Anh-Việt

Lớp tín chỉ: D23CQCN04-B
Giảng viên hướng dẫn: TS. Kim Ngọc Bách
Sinh viên thực hiện: Nguyễn Đức Trung
Mã sinh viên: B23DCCN858

Hà Nội 2026

MỤC LỤC

I. MỤC TIÊU CỦA TUẦN LÀM VIỆC 2
1. Mục tiêu 2
2. Nội dung đã thực hiện 2
3. Kết quả đạt được 5
4. Kế hoạch tuần tới 5

I. MỤC TIÊU CỦA TUẦN LÀM VIỆC

1. Mục tiêu

- Bắt đầu finetune bằng LoRA
- Train thử train 1 epcho và đánh giá kết quả trên thang đo BLEU, so sánh với kết quả trước khi finetune.
- Toàn bộ code và quá trình finetune ở trong file *finetune-medev-envit5-translation-h100.ipynb*

2. Nội dung đã thực hiện

a. Chuẩn bị dữ liệu

- Dữ liệu được tải trực tiếp từ HuggingFace bằng thư viện datasets.
- Trong MedEV, dữ liệu được lưu dưới dạng hai nửa riêng biệt:
    - nửa đầu: câu tiếng Anh
    - nửa sau: câu tiếng Việt

➔ Cần sử dụng offset để ghép cặp song ngữ

- Để giảm thời gian huấn luyện, lấy 30,000 cặp câu từ tập dữ liệu với tập train 24,000; tập validation: 3,000; tập test: 3,000.

b. Tokenization

- Đây là bước chuyển văn bản thành vector số để mô hình có thể hiểu được.

Tokenization được thực hiện bằng tokenizer của mô hình.

```
tokenizer = AutoTokenizer.from_pretrained(model_name, use_fast=False)
```

Sau đó áp dụng tokenization cho toàn bộ dataset

```python
def preprocess_function(examples):
    inputs = ["en: " + doc for doc in examples["en"]]
    model_inputs = tokenizer(inputs, max_length=512, truncation=True)

    targets = ["vi: " + doc for doc in examples["vi"]]
    labels = tokenizer(text_target=targets, max_length=512, truncation=True)

    labels_input_ids = labels["input_ids"]
    labels_input_ids = [
        [(l if l != tokenizer.pad_token_id else -100) for l in label]
        for label in labels_input_ids
    ]

    model_inputs["labels"] = labels_input_ids
    return model_inputs

tokenized_raw = raw.map(
    preprocess_function,
    batched=True,
    remove_columns=raw["train"].column_names
)
```

```
Map: 100%  24000/24000 [00:06<00:00, 3880.33 examples/s]
Map: 100%  3000/3000 [00:00<00:00, 4034.82 examples/s]
Map: 100%  3000/3000 [00:00<00:00, 4099.55 examples/s]
```

c. Load mô hình

- Mô hình được load từ HuggingFace.

```python
model_name = "VietAI/envit5-translation"
```

```python
from transformers import AutoModelForSeq2SeqLM
model = AutoModelForSeq2SeqLM.from_pretrained(
    model_name,
    torch_dtype=torch.float16,
    device_map="auto",
    low_cpu_mem_usage=True
)
```

```
config.json: 100%  721/721 [00:00<00:00, 134kB/s]
pytorch_model.bin: 100%  1.10G/1.10G [00:07<00:00, 278MB/s]
```

+ Code + Markdown

```python
tokenizer = AutoTokenizer.from_pretrained(model_name, use_fast=False)
```

```
tokenizer_config.json: 1.19k/? [00:00<00:00, 174kB/s]
spiece.model: 100%  1.10M/1.10M [00:00<00:00, 1.17MB/s]
special_tokens_map.json: 1.11k/? [00:00<00:00, 177kB/s]
tokenizer.json: 3.49M/? [00:00<00:00, 13.8MB/s]
```

- Để giảm số lượng tham số cần huấn luyện, sử dụng phương pháp LoRA.
- LoRA chỉ thêm các low-rank adapters vào các lớp attention thay vì cập nhật toàn bộ trọng số của mô hình.

```
config = LoraConfig(
    r=16,
    lora_alpha=32,
    target_modules=["k","q","v","o"],
    lora_dropout=0.05,
    bias="none",
    task_type="SEQ_2_SEQ_LM"
)
model = get_peft_model(model, config)
model.print_trainable_parameters()
```

```
trainable params: 3,538,944 || all params: 278,641,920 || trainable%: 1.2701
```

d. Cấu hình huấn luyện

- Quá trình huấn luyện được thực hiện bằng Seq2SeqTrainer và Seq2SeqTrainingArguments.

```
targs = Seq2SeqTrainingArguments(
    output_dir="./finetuned_model",
    fp16=True,
    bf16=False,
    per_device_train_batch_size=8,
    per_device_eval_batch_size=8,
    gradient_accumulation_steps=4,
    learning_rate=2e-4,
    num_train_epochs=1,
    logging_steps=250,
    save_strategy="steps",
    eval_strategy="epoch",
    save_steps=250,
    save_total_limit=2,
    report_to="none",
    group_by_length=True,
    ddp_find_unused_parameters=False,
    dataloader_num_workers=4,
    remove_unused_columns=False,
    predict_with_generate=True,
    generation_max_length=512
)
```

```
trainer = Seq2SeqTrainer(
    model=model,
    args=targs,
    train_dataset=tokenized_raw["train"],
    eval_dataset=tokenized_raw["test"],
    data_collator=data_collator,
    compute_metrics=compute_metrics
)
```

- Huấn luyện được thực hiện trên GPU: NVIDIA H100, GPU này có dung lượng VRAM lớn và khả năng tính toán cao, cho phép huấn luyện mô hình nhanh chóng.

3. Kết quả đạt được

Sau 1 epoch, kết quả thu được:

Epoch	Training Loss	Validation Loss	BLEU
1	1.1088	1.0133	46.36

- Giá trị loss không cao đối khi chỉ train với 1 epoch.
- Nhưng chỉ với 1 epoch, so với mô hình trước khi fintune, BLEU đã tăng khoảng 6 điểm, cho thấy việc finetune với MedEV giúp cải thiện đáng kể khả năng dịch trong miền y khoa.

4. Kế hoạch tuần tới

- Tăng số lượng epoch lên 3-4 epoch, rồi đánh giá kết quả
- Tăng số lượng data rồi đánh giá kết quả
- Đánh giá trên 2 metric khác nữa là TER và METEOR.