HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN

THỰC TẬP CƠ SỞ

BÁO CÁO TUẦN

Đề tài: Finetune mô hình dịch máy Neural cho văn bản chuyên ngành y khoa Anh-Việt

Lớp tín chỉ:	**D23CQCN04-B**
Giảng viên hướng dẫn:	**TS. Kim Ngọc Bách**
Sinh viên thực hiện:	**Nguyễn Đức Trung**
Mã sinh viên:	**B23DCCN858**

Hà Nội 2026

MỤC LỤC

DANH MỤC VIẾT TẮT 2
I. MỤC TIÊU CỦA TUẦN LÀM VIỆC 2
1. Mục tiêu 2
2. Nội dung đã thực hiện 2
3. Kết quả đạt được 3
4. Kế hoạch tuần tới 3
II. CHI TIẾT NGHIÊN CỨU VÀ KHẢO SÁT 3
1. Neural Machine Translation 3
2. Kiến trúc Transformer 4
3. Fine-tuning 6
4. Mô hình EnViT5 7
5. Bộ dữ liệu MedEV 8
THAM KHẢO 8

DANH MỤC VIẾT TẮT

Từ viết tắt	Tên đầy đủ	Giải thích
NMT	Neural Machine Translation	dịch máy dựa trên mạng nơ-ron
RNN	Recurrent Neural Networks	Mạng nơ-ron hồi quy
LSTM	Long Short-Term Memory	Một dạng mạng nơ-ron hồi quy (RNN) tiên tiến

I. MỤC TIÊU CỦA TUẦN LÀM VIỆC

1. Mục tiêu

- Nghiên cứu tổng quan về lĩnh vực dịch máy nơ-ron (NMT) và kiến trúc Transformer.
- Tìm hiểu phương pháp fine-tuning và thích nghi miền (domain adaptation).
- Khảo sát mô hình EnViT5 và tập dữ liệu chuyên nghành MedEV.

2. Nội dung đã thực hiện

a. Nghiên cứu cơ sở lý thuyết về NMT và Transformer

- Neural Machine Translation (NMT): Đã tìm hiểu về cơ chế dịch máy dựa trên mạng nơ-ron sâu, sử dụng cấu trúc encoder–decoder để học ánh xạ trực tiếp từ câu nguồn sang câu đích thay vì các phương pháp thống kê cũ.

- Kiến trúc Transformer: Nghiên cứu sâu về cơ chế multi-head attention, cho phép mô hình nắm bắt ngữ cảnh toàn cục của câu và hỗ trợ xử lý song song, giúp tăng tốc độ huấn luyện và hiệu năng dịch thuật.

b. Nghiên cứu kỹ thuật Fine-tuning và Domain Adaptation

- Tiếp tục huấn luyện mô hình đã có sẵn trên tập dữ liệu chuyên biệt để mô hình thích nghi với thuật ngữ y khoa.
- Đề xuất phương pháp finetuning bằng kĩ thuật LoRA

c. Khảo sát công cụ và dữ liệu thực nghiệm

- Mô hình EnViT5: Tìm hiểu về mô hình dịch Anh–Việt nền tảng được xây dựng trên kiến trúc Transformer.
- Bộ dữ liệu MedEV: Khảo sát tập dữ liệu gồm 360.000 cặp câu song ngữ Anh–Việt chuyên ngành y sinh học. Đây là nguồn dữ liệu quan trọng để bổ sung các thuật ngữ chuyên môn mà các dữ liệu tổng quát còn thiếu hụt.
- Công nghệ: Lựa chọn thư viện Hugging Face Transformers để triển khai mô hình và thực hiện quá trình tinh chỉnh.

3. Kết quả đạt được

- Nắm vững kiến thức nền tảng về Neural Machine Translation và Transformer.
- Cơ bản giải quyết được hiện tượng "catastrophic forgetting" (quên kiến thức cũ) và giảm tài nguyên tính toán đáng kể khi lựa chọn phương pháp LoRA trong quá trình finetuning
- Xác định rõ vai trò của mô hình EnViT5 và cách thức khai thác dữ liệu MedEV cho dự án.

4. Kế hoạch tuần tới

- Bắt đầu giai đoạn chuẩn bị dữ liệu: Thu thập và xử lý bộ dữ liệu MedEV
- Thực hiện các bước tiền xử lý: làm sạch dữ liệu, chuẩn hóa văn bản và thực hiện tokenization phù hợp với mô hình EnViT5.

II. CHI TIẾT NGHIÊN CỨU VÀ KHẢO SÁT

1. Neural Machine Translation

Dịch máy là một trong những bài toán quan trọng trong xử lý ngôn ngữ tự nhiên. Các hệ thống dịch máy truyền thống trước đây chủ yếu dựa trên phương pháp thống kê (Statistical Machine Translation – SMT) [1], trong đó quá trình dịch được thực hiện thông qua việc ước lượng xác suất của các cụm từ giữa hai ngôn ngữ.

Sự ra đời của Neural Machine Translation (NMT) đã tạo ra bước tiến lớn trong lĩnh vực dịch máy. NMT sử dụng các mạng nơ-ron sâu để học trực tiếp ánh xạ giữa câu nguồn và câu đích thông qua dữ liệu song ngữ. Thay vì tách riêng nhiều thành phần như trong SMT, mô hình NMT xây dựng một kiến trúc end-to-end, cho phép toàn bộ quá trình dịch được tối ưu hóa đồng thời trong quá trình huấn luyện.

Điểm mạnh quan trọng của NMT là khả năng học biểu diễn ngữ nghĩa của câu ở mức ngữ cảnh, giúp mô hình hiểu được ý nghĩa tổng thể thay vì chỉ dựa vào từng cụm từ riêng lẻ. Nhờ đó, NMT có thể xử lý tốt hơn các hiện tượng ngôn ngữ như đa nghĩa, thay đổi trật tự từ giữa các ngôn ngữ hoặc phụ thuộc dài trong câu. Đặc biệt, trong các bài toán dịch chuyên ngành như y sinh học – nơi các thuật ngữ và cấu trúc câu thường phức tạp – khả năng học biểu diễn ngữ nghĩa sâu của NMT đóng vai trò quan trọng trong việc đảm bảo độ chính xác của bản dịch.

Thông qua quá trình tìm hiểu về NMT, có thể rút ra rằng việc sử dụng các mô hình dịch máy dựa trên mạng nơ-ron là lựa chọn phù hợp cho bài toán dịch văn bản y sinh, bởi chúng có khả năng học trực tiếp từ dữ liệu và thích nghi tốt với các miền ngôn ngữ chuyên biệt khi được huấn luyện hoặc tinh chỉnh trên dữ liệu chuyên ngành.

2. Kiến trúc Transformer

Mặc dù các mô hình NMT ban đầu sử dụng mạng hồi tiếp (RNN) [2] hoặc LSTM (một dạng cải tiến của RNN) [3] để xử lý chuỗi văn bản, các kiến trúc này vẫn tồn tại một số hạn chế quan trọng.

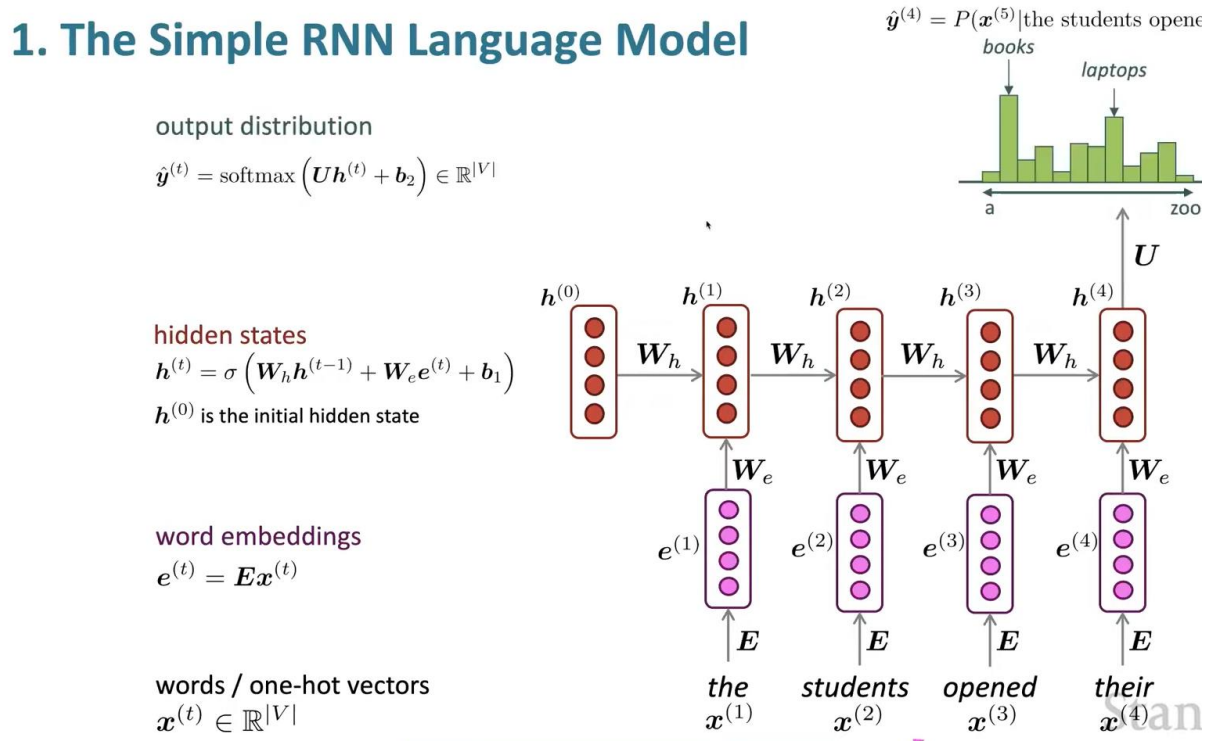

Hình 1: Kiến trúc RNN

Do tính chất xử lý tuần tự, RNN gặp khó khăn trong việc khai thác quan hệ giữa các từ ở khoảng cách xa nghĩa là khi câu càng dài thì ma trận nó sẽ không chứa hết được kiến thức nên dẫn đến các câu đầu tiên nó sẽ bị mờ dần (hay quên) và thứ hai kiến trúc RNN khó song song hóa trong quá trình huấn luyện. Điều này làm giảm

hiệu quả khi xử lý các câu dài hoặc các văn bản có cấu trúc phức tạp như trong tài liệu khoa học và y sinh học.

Để giải quyết những hạn chế này, kiến trúc Transformer được đề xuất trong nghiên cứu Attention Is All You Need [4]. Điểm khác biệt cốt lõi của Transformer là việc loại bỏ hoàn toàn các cấu trúc tuần tự như RNN và thay thế bằng cơ chế self-attention. Cơ chế này cho phép mỗi token trong câu trực tiếp xem xét toàn bộ các token khác trong chuỗi khi xây dựng biểu diễn ngữ nghĩa của mình.

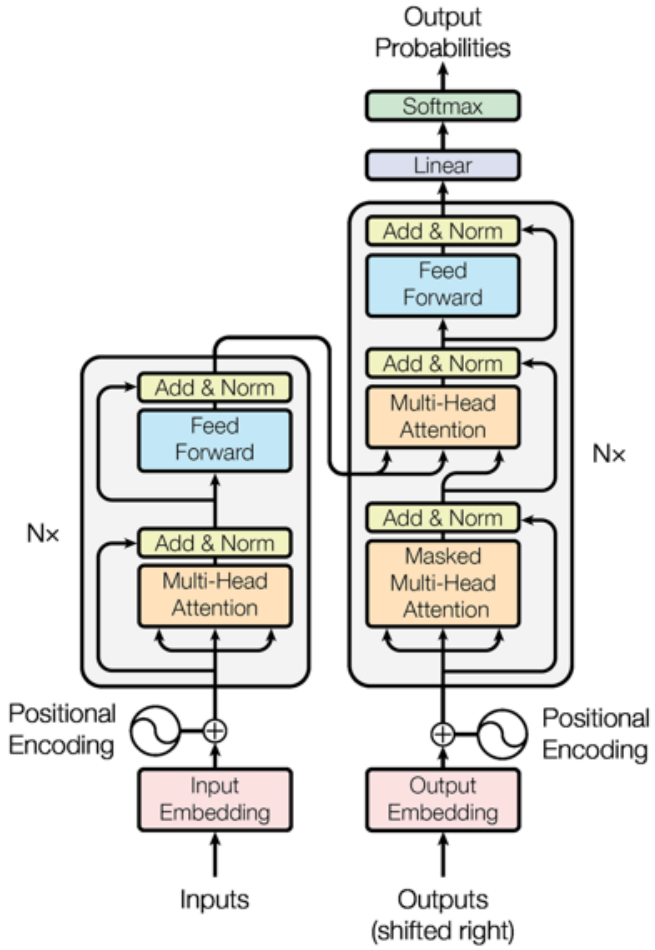

Hình 2: Kiến trúc Transformer

Nhờ self-attention, Transformer có khả năng mô hình hóa các quan hệ ngữ nghĩa dài hạn một cách hiệu quả hơn so với RNN. Đồng thời, cơ chế multi-head attention (hay nói cách khác là chồng nhiều self-attention lên nhau) điều này cho phép mô hình học nhiều loại quan hệ ngữ nghĩa khác nhau giữa các từ, ví dụ như quan hệ cú pháp, quan hệ ngữ nghĩa hoặc sự phụ thuộc giữa các thành phần trong câu, …. Khả năng học các quan hệ đa chiều này đặc biệt quan trọng trong các văn bản chuyên ngành, nơi mà ý nghĩa của một thuật ngữ có thể phụ thuộc mạnh vào ngữ cảnh xung quanh.

Một ưu điểm quan trọng khác của Transformer là khả năng xử lý song song toàn bộ chuỗi đầu vào. Không giống như RNN phải xử lý từng token theo thứ tự thời gian, Transformer cho phép tính toán đồng thời trên toàn bộ câu. Điều này giúp tăng đáng kể tốc độ huấn luyện và cho phép huấn luyện các mô hình lớn trên tập dữ liệu quy mô lớn.

Đối với bài toán dịch Anh–Việt trong lĩnh vực y sinh học, các đặc điểm của Transformer đặc biệt phù hợp. Văn bản y khoa thường chứa nhiều thuật ngữ dài và các cấu trúc câu phức tạp, trong đó ý nghĩa của một thuật ngữ có thể phụ thuộc vào nhiều thành phần khác trong câu. Khả năng nắm bắt ngữ cảnh toàn cục của Transformer giúp mô hình xử lý tốt hơn các trường hợp này, từ đó cải thiện độ chính xác của bản dịch.

Từ quá trình khảo sát trên, có thể thấy rằng Transformer cung cấp nền tảng phù hợp cho các hệ thống dịch máy hiện đại. Vì vậy, nghiên cứu lựa chọn các mô hình dịch máy dựa trên Transformer làm cơ sở cho hệ thống dịch Anh–Việt trong lĩnh vực y sinh học.

3. Fine-tuning

Mặc dù các mô hình dịch máy đã được huấn luyện trước có khả năng dịch tổng quát khá tốt giữa các ngôn ngữ, hiệu quả của chúng trong các lĩnh vực chuyên ngành như y sinh học vẫn còn hạn chế do sự khác biệt về thuật ngữ và ngữ cảnh. Do đó, việc tinh chỉnh mô hình trên dữ liệu thuộc miền chuyên ngành là cần thiết nhằm cải thiện chất lượng dịch trong các ngữ cảnh cụ thể. Thay vì thực hiện fine-tuning toàn bộ tham số của mô hình, phương pháp Low-Rank Adaptation (LoRA) được lựa chọn để thích nghi mô hình với dữ liệu y khoa.

a. Tổng quan về phương pháp LoRA

LoRA (Low-Rank Adaptation) [5] là một phương pháp fine-tuning hiệu quả được đề xuất nhằm giảm chi phí tính toán khi tinh chỉnh các mô hình học sâu có số lượng tham số lớn. Thay vì cập nhật toàn bộ trọng số của mô hình trong quá trình huấn luyện, LoRA giữ nguyên các tham số của mô hình đã được tiền huấn luyện và chỉ bổ sung các ma trận có hạng thấp (low-rank matrices) vào một số lớp nhất định của mạng nơ-ron, thường là các lớp attention trong kiến trúc Transformer.

Cụ thể, nếu một ma trận trọng số gốc W' được sử dụng trong mô hình, LoRA không trực tiếp cập nhật ma trận này mà biểu diễn sự thay đổi của nó dưới dạng tích của hai ma trận có kích thước nhỏ hơn A và B, sao cho:

$$W = W' + AB$$

Trong đó A và B là các ma trận có hạng thấp với số lượng tham số nhỏ hơn đáng kể so với ma trận gốc. Nhờ đó, số lượng tham số cần huấn luyện được giảm mạnh, giúp tiết kiệm bộ nhớ GPU và tăng tốc quá trình huấn luyện.

Một ưu điểm quan trọng của LoRA là khả năng giữ nguyên tri thức của mô hình đã được tiền huấn luyện, đồng thời cho phép mô hình thích nghi với miền dữ liệu mới thông qua các tham số bổ sung. Phương pháp này đặc biệt hữu ích trong các trường hợp tài nguyên tính toán hạn chế hoặc khi cần fine-tune nhiều mô hình cho các miền dữ liệu khác nhau.

LoRA là một phương pháp cực kì thích hợp để finetuning EnViT5 trên dữ liệu y sinh học nhằm giúp mô hình thích nghi với các thuật ngữ chuyên ngành mà không cần cập nhật toàn bộ tham số của mô hình.

b. Yêu cầu tài nguyên và các lưu ý khi sử dụng LoRA

Việc sử dụng LoRA giúp giảm đáng kể yêu cầu về tài nguyên tính toán so với phương pháp fine-tuning toàn bộ mô hình. Trong nhiều trường hợp, mô hình có thể được huấn luyện trên một GPU với dung lượng bộ nhớ trung bình mà vẫn đạt hiệu quả tốt.

Tuy nhiên, khi triển khai cần lưu ý một số điểm quan trọng. Thứ nhất, việc lựa chọn vị trí chèn LoRA trong mô hình có thể ảnh hưởng đến hiệu quả huấn luyện; thông thường các lớp attention là vị trí phù hợp nhất. Thứ hai, giá trị của tham số rank cần được lựa chọn hợp lý: rank quá nhỏ có thể hạn chế khả năng thích nghi của mô hình, trong khi rank quá lớn sẽ làm tăng chi phí tính toán. Ngoài ra, cần lựa chọn learning rate phù hợp để đảm bảo quá trình huấn luyện ổn định và tránh hiện tượng quá khớp trên dữ liệu chuyên ngành.

LoRA làm giảm đáng kể hiện tượng “catastrophic forgetting” (quên kiến thức cũ), nhờ cơ chế của LoRA là chỉ dồn thêm một ma trận trọng số nữa mà không finetune lại toàn bộ trọng số mô hình, nhưng vẫn có thể xảy ra nếu các ma trận mới quá lớn hoặc dữ liệu finetune bị bias (overfit vào dataset mới), nên vẫn phải cẩn thận trong quá trình finetune khi sử dụng LoRA.

4. Mô hình EnViT5

Trong các mô hình dịch máy dựa trên Transformer, các mô hình pre-trained ngày càng đóng vai trò quan trọng nhờ khả năng tận dụng tri thức ngôn ngữ đã được học từ các tập dữ liệu lớn. Một trong những mô hình nổi bật cho bài toán dịch giữa tiếng Anh và tiếng Việt là EnViT5 [6] [7].

EnViT5 được xây dựng dựa trên kiến trúc T5 (Text-to-Text Transfer Transformer), trong đó mọi bài toán NLP đều được biểu diễn dưới dạng bài toán chuyển đổi văn bản sang văn bản. Nhờ cách tiếp cận thống nhất này, mô hình có thể dễ dàng áp

dụng cho nhiều nhiệm vụ khác nhau, bao gồm dịch máy, tóm tắt văn bản, trả lời câu hỏi hoặc sinh văn bản.

Điểm mạnh của EnViT5 nằm ở việc mô hình đã được huấn luyện trước trên một lượng lớn dữ liệu song ngữ Anh – Việt. Điều này giúp mô hình học được nhiều đặc điểm quan trọng của hai ngôn ngữ như cấu trúc câu, cách biểu đạt ý nghĩa và sự khác biệt về trật tự từ. Nhờ đó, mô hình có khả năng tạo ra các bản dịch tự nhiên và chính xác hơn so với việc huấn luyện mô hình từ đầu.

EnViT5 là lựa chọn phù hợp vì một số lý do chính. Trước hết, đây là mô hình đã được tối ưu cho cặp ngôn ngữ Anh – Việt, giúp giảm đáng kể chi phí huấn luyện so với việc xây dựng một hệ thống dịch hoàn toàn mới. Thứ hai, kiến trúc T5 cho phép mô hình dễ dàng được tinh chỉnh trên các tập dữ liệu chuyên ngành như dữ liệu y sinh học. Điều này đặc biệt quan trọng trong bối cảnh các thuật ngữ y khoa thường có nghĩa chuyên biệt và cần được dịch chính xác.

Có thể nhận thấy rằng việc sử dụng các mô hình dịch máy đã được huấn luyện trước không chỉ giúp tận dụng tri thức ngôn ngữ sẵn có mà còn tạo điều kiện thuận lợi cho việc thích nghi mô hình với các miền dữ liệu chuyên ngành thông qua quá trình tinh chỉnh sau này.

5. Bộ dữ liệu MedEV

Để thực hiện quá trình fine-tuning, nghiên cứu sử dụng bộ dữ liệu MedEV [8], bao gồm khoảng 360.000 cặp câu song ngữ Anh–Việt trong lĩnh vực y sinh học. Dữ liệu được thu thập từ các nguồn y khoa uy tín như tóm tắt bài báo khoa họ, cẩm nang MSD Manuals, tóm tắt luận án tiến sĩ và các bài báo được các bác sĩ dịch thuật. Nội dung dữ liệu bao phủ nhiều chủ đề như bệnh học, dược học, điều trị lâm sàng và nghiên cứu y sinh.

So với các tập dữ liệu tổng quát được sử dụng trong giai đoạn tiền huấn luyện của EnViT5, MedEV có tính chuyên biệt cao về miền dữ liệu. Việc sử dụng bộ dữ liệu này giúp mô hình tiếp cận các thuật ngữ y khoa, tên bệnh, tên thuốc và cấu trúc câu học thuật mà dữ liệu tổng quát thường không bao phủ đầy đủ.

THAM KHẢO

[1] P. Koehn, F. J. Och và D. Marcu, “Statistical Phrase-Based Translation,” trong *Proceedings of the 2003 Human Language Technology Conference of the North American Chapter of the Association for Computational Linguistics*, Edmonton, 2003.

[2] I. Sutskever, O. Vinyals và Q. V. Le, “Sequence to Sequence Learning with Neural Networks,” *Advances in Neural Information Processing Systems,* tập 27, pp. 3104-3112, 2014.

[3] S. Hochreiter và J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation,* tập 9, số 8, pp. 1735-1780, 1997.

[4] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser và I. Polosukhin, “Attention Is All You Need,” trong *Advances in Neural Information Processing Systems (NIPS)*, Long Beach, CA, 2017.

[5] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang và W. Chen, “LoRA: Low-Rank Adaptation of Large Language Models,” trong *International Conference on Learning Representations (ICLR)*, Online, 2022.

[6] C. Ngo, T. H. Trinh, L. Phan, H. Tran, T. Dang, H. Nguyen, M. Nguyen và M.-T. Luong, “EnViT5: English–Vietnamese Translation Model,” VietAI, 2022. [Trực tuyến]. Available: https://huggingface.co/VietAI/envit5-translation. [Đã truy cập 27 February 2026].

[7] C. Ngo, T. H. Trinh, L. Phan, H. Tran, T. Dang, H. Nguyen, M. Nguyen và M.-T. Luong, “MTet: Multi-domain Translation for English and Vietnamese,” *arXiv preprint arXiv:2210.05610,* 2022.

[8] N. Vo, D. Q. Nguyen, D. D. Le, M. Piccardi và W. Buntine, “Improving Vietnamese-English Medical Machine Translation,” trong *Proceedings of the Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, Torino, Italy, 2024.