HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN

THỰC TẬP CƠ SỞ

BÁO CÁO TUẦN

Đề tài: Finetune mô hình dịch máy Neural cho văn bản chuyên ngành y khoa Anh-Việt

Lớp tín chỉ: D23CQCN04-B
Giảng viên hướng dẫn: TS. Kim Ngọc Bách
Sinh viên thực hiện: Nguyễn Đức Trung
Mã sinh viên: B23DCCN858

Hà Nội 2026

MỤC LỤC

I. MỤC TIÊU CỦA TUẦN LÀM VIỆC 2

1. Mục tiêu 2

2. Nội dung đã thực hiện 2

3. Kết quả đạt được 3

4. Kế hoạch tuần tới 3

II. CHI TIẾT NGHIÊN CỨU VÀ KHẢO SÁT 3

1. Thang đo TER trong đánh giá dịch máy 3

2. Thang đo METEOR trong đánh giá dịch máy 4

I. MỤC TIÊU CỦA TUẦN LÀM VIỆC

1. Mục tiêu

- Đánh giá mô hình EnViT5 trước khi fine-tuning bằng nhiều thang đo khác nhau.
- Mở rộng phương pháp đánh giá ngoài BLEU bằng các metric hiện đại hơn.
- Chuẩn hóa lại tập dữ liệu 30.000 mẫu phục vụ huấn luyện.
- Chuẩn bị các bước cần thiết trước khi tiến hành training.

2. Nội dung đã thực hiện

a. Đánh giá mô hình với nhiều metric

Trong tuần này, ngoài BLEU score, mô hình được đánh giá thêm bằng hai thang đo là TER và METEOR nhằm có cái nhìn đa chiều hơn về chất lượng dịch.

- BLEU : 0.4084
- TER : 54.4297
- METEOR : 0.6491

Code lưu trong file:
evaluate-by-bleu-ter-meteor-score.ipynb (thư mục sourceCode).

Việc bổ sung các metric này giúp đánh giá mô hình không chỉ dựa trên mức độ trùng lặp từ vựng như BLEU, mà còn xét đến khoảng cách chỉnh sửa như TER và mức độ tương đồng ngữ nghĩa như METEOR.

b. Chuẩn hóa phương pháp chọn tập dữ liệu

Tập dữ liệu 30.000 mẫu được trích xuất từ bộ MedEV thông qua phương pháp lấy mẫu ngẫu nhiên có kiểm soát được gọi là controlled random sampling.

Cụ thể:

- Dữ liệu được shuffle với seed cố định
- Sau đó chọn 30.000 mẫu
- Chia thành: 24k train – 3k validation – 3k test

Việc sử dụng seed giúp:

- Đảm bảo tính tái lập kết quả
- Tránh bias dữ liệu theo từng domain nhỏ

Phương pháp này giúp dữ liệu:

- Được phân bố đều trên nhiều chủ đề y sinh
- Tăng tính đa dạng

3. Kết quả đạt được

- Thiết lập hệ thống đánh giá mô hình với 3 metric: BLEU, TER, METEOR
- Xây dựng baseline đa chiều cho mô hình trước khi fine-tuning
- Hoàn thiện tập dữ liệu 30.000 mẫu với phân bố hợp lý

4. Kế hoạch tuần tới

- Bắt đầu fine-tuning mô hình bằng LoRA
- Theo dõi loss và metric trên validation set
- So sánh hiệu năng trước và sau huấn luyện

II. CHI TIẾT NGHIÊN CỨU VÀ KHẢO SÁT

1. Thang đo TER trong đánh giá dịch máy

TER (Translation Edit Rate) là một thước đo đánh giá chất lượng bản dịch dựa trên số lượng thao tác chỉnh sửa cần thiết để biến bản dịch của mô hình thành bản dịch tham chiếu. Các thao tác chỉnh sửa bao gồm: chèn, xóa, thay thế, hoán đổi vị trí. Thang đo có công thức như sau:

$$TER = \frac{Số\ phép\ chỉnh\ sửa}{\text{Độ}\ dài\ câu\ tham\ chiếu}$$

TER có giá trị càng thấp thì bản dịch càng tốt, ngược lại TER càng cao thì bản dịch sai lệch lớn.

Ưu điểm của TER:

- Đánh giá trực tiếp chi phí sửa lỗi
- Dễ hiểu và trực quan

- Phù hợp với các bài toán cần độ chính xác cao

Nhược điểm của TER:

- Không đánh giá được tính tự nhiên của câu
- Không phản ánh đầy đủ ngữ nghĩa
- Có thể đánh giá các thấp câu đúng ngữ nghĩa nhưng khác cách diễn đạt

2. Thang đo METEOR trong đánh giá dịch máy

METEOR (Metric for Evaluation of Translation with Explicit ORdering) [1] được đề xuất nhằm cải thiện các hạn chế của BLEU bằng cách đánh giá sâu hơn về ngữ nghĩa.

Thuật toán này hoạt động qua 2 bước chính:

Bước 1: Khớp từ

Nó sẽ cố gắng nối khớp các từ ở bản dịch cần đánh giá so với bản dịch đúng (ground truth), việc so khớp này bằng cách sử dụng các module bên ngoài để tính toán theo thứ tự ưu tiên như sau:

1. Exact: khớp chính xác từng chữ (VD: “computer” nối với “computer”)
2. Stem: khớp các từ có chung gốc (VD: “computers” nối với “computer”)
3. Synonym: khớp các từ đồng nghĩa (VD: “thông minh” nối với “sáng dạ”)

Bước 2: Tính điểm

- Tính 2 giá trị :
    - Precision (P) : Tỷ lệ từ khớp với bản dịch đúng trên tổng số từ máy dịch
    - Recall (R): Tỷ lệ từ khớp trên tổng số từ của bản dịch đúng (ground truth)
- Sau đó, kết hợp P và R, nhưng ưu tiên Recall gấp 9 lần Precision vì nghiên cứu cho thấy Recall phản ánh chất lượng dịch tốt hơn đối với con người:

$$F_{mean} = \frac{10PR}{R + 9P}$$

- Sẽ có một hình phạt để kiểm soát ngữ pháp, nếu các từ có bản dịch đúng ngữ pháp, đồng nghĩa các từ sẽ không bị nhảy lung tung, nếu nhảy lung tung thì nó sẽ tạo ra nhiều cụm riêng lẽ đồng nghĩa hình phạt sẽ càng lớn và ngược lại:

$$Penalty = 0.5 * (\frac{Số\ lượng\ cụm}{Số\ lượng\ từ\ khớp})$$

    - Hệ số 0.5: Đây là mức phạt tối đa (50%). Nếu bản dịch bị xáo trộn, hình phạt sẽ tiến gần đến 0.5

- VD: Ta có một câu là: "The cat sat on the mat". Nếu máy dịch chính xác là "The cat sat on the mat" thì chỉ có 1 cụm nên hình phạt là 0.5x(1/6) = 0.083. Còn nếu máy dịch là “Mat the on sat cat the” thì có tới 6 cụm và hình phạt là 0.5(6/6) = 0.5

- Cuối cùng, kết hợp với penalty, ta có:

$$F_{mean} = 1 - penalty$$

Ưu điểm:

- Tương quan cao với đánh giá của con người: Đây là ưu điểm lớn nhất. Các nghiên cứu cho thấy điểm METEOR thường "khớp" với cảm nhận của con người về một bản dịch tốt hơn là điểm BLEU.
- Coi trọng Recall : BLEU thường chỉ quan tâm máy dịch có bị thừa/sai từ không , trong khi METEOR hiểu rằng việc dịch đủ ý của bản gốc là cực kỳ quan trọng để giữ trọn vẹn thông tin.
- Linh hoạt với từ đồng nghĩa và biến thể: Nhờ các mô-đun Stemming và Synonym, METEOR không "phạt oan" những bản dịch sáng tạo.

Nhược điểm:

- Phụ thuộc vào tài nguyên ngôn ngữ: Đây là rào cản lớn nhất. Để METEOR chạy tốt, nó cần bộ từ điển đồng nghĩa (WordNet) và bộ tách gốc từ (Stemmer) chuẩn cho từng ngôn ngữ.
- Tốc độ tính toán chậm hơn: So với BLEU (vốn chỉ là đếm từ đơn thuần), METEOR phải thực hiện các bước căn chỉnh (Alignment) và tra cứu từ điển/thuật toán phức tạp nên sẽ tốn thời gian hơn khi đánh giá các bộ dữ liệu khổng lồ.
- Vẫn chưa hiểu được ngữ nghĩa sâu sắc: Dù có từ đồng nghĩa, METEOR vẫn dựa trên việc so khớp từ-với-từ. Nó chưa thể hiểu được các cấu trúc ngữ pháp phức tạp hoặc những cách diễn đạt hoàn toàn khác nhau nhưng cùng ý nghĩa (paraphrasing) nếu chúng không nằm trong từ điển đồng nghĩa.

THAM KHẢO

[1] S. Banerjee and A. Lavie, "METEOR: An Automatic Metric for MT Evaluation with Improved Correlation with Human Judgments," in *Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization*, Ann Arbor, Michigan, 2005.