HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN

THỰC TẬP CƠ SỞ

BÁO CÁO TUẦN

Đề tài: Finetune mô hình dịch máy Neural cho văn bản chuyên ngành y khoa Anh-Việt

Lớp tín chỉ: D23CQCN04-B
Giảng viên hướng dẫn: TS. Kim Ngọc Bách
Sinh viên thực hiện: Nguyễn Đức Trung
Mã sinh viên: B23DCCN858

Hà Nội 2026

MỤC LỤC

I. MỤC TIÊU CỦA TUẦN LÀM VIỆC 2

1. Mục tiêu 2

2. Nội dung đã thực hiện 2

3. Kết quả đạt được 3

4. Kế hoạch tuần tới 3

I. MỤC TIÊU CỦA TUẦN LÀM VIỆC

1. Mục tiêu

- **Xây dựng khung mã nguồn :** Hoàn thiện quy trình từ cài đặt thư viện, load dữ liệu đến cấu hình mô hình trên môi trường Kaggle.
- **Cấu hình tham số LoRA:** Xác định các lớp mục tiêu (target modules) và các siêu tham số (r, alpha) phù hợp với kiến trúc EnViT5.
- **Thiết lập Pipeline huấn luyện:** Xây dựng các hàm tiền xử lý dữ liệu (preprocess), hàm tính toán metric và cấu hình Seq2SeqTrainer.
- **Kiểm tra tính sẵn sàng của phần cứng:** Đảm bảo môi trường GPU (T4) nhận diện tốt mô hình và sẵn sàng cho quá trình forward pass.

2. Nội dung đã thực hiện

a. Hoàn thành khung mã nguồn xử lý dữ liệu

Dựa trên tập dữ liệu 30.000 mẫu đã chuẩn hóa ở tuần trước, mã nguồn tuần này đã thiết lập các bước:

- **Tiền xử lý:** Xây dựng hàm preprocess_function để thêm prefix "en: " cho câu nguồn và "vi: " cho câu đích, đồng thời thực hiện tokenize với độ dài tối đa 512 tokens.
- **Xử lý nhãn (Labels):** Thiết lập việc thay thế các token padding bằng giá trị -100 để bỏ qua khi tính loss trong quá trình huấn luyện.

b. Cấu hình kiến trúc LoRA cho EnViT5

Thay vì tinh chỉnh toàn bộ tham số, phương pháp LoRA (Low-Rank Adaptation) đã được cấu hình để tối ưu tài nguyên:

- **Target Modules:** Tập trung vào các lớp nội tại của cơ chế Attention bao gồm "k", "q", "v", "o".

- **Thông số kỹ thuật:** Thiết lập rank r = 16 và lora_alpha = 32 với dropout = 0.05 để cân bằng giữa khả năng học và tránh overfitting.
- **Kiểm tra tham số:** Sử dụng hàm print_trainable_parameters() để xác nhận tỉ lệ tham số huấn luyện (thường chiếm tỷ lệ rất nhỏ so với tổng tham số mô hình).

c. Thiết lập bộ công cụ huấn luyện

Metric Integration: Tích hợp bộ đo sacrebleu vào hàm compute_metrics để theo dõi hiệu năng ngay trong lúc train.

Training Arguments: Cấu hình Seq2SeqTrainingArguments với các tham số tối ưu cho GPU T4:

- per_device_train_batch_size = 8 kết hợp gradient_accumulation_steps = 4 (tương đương effective batch size là 32).
- Sử dụng fp16 để tăng tốc độ tính toán và giảm bộ nhớ GPU.
- Chiến lược lưu trữ (save strategy) và đánh giá (eval strategy) được thiết lập theo từng epoch/steps để tránh mất mát dữ liệu khi gặp sự cố.

3. Kết quả đạt được

- **Hoàn thành file notebook khung:** finetune-medev-envit5-translation.ipynb đã sẵn sàng thực thi mà không có lỗi cú pháp.
- **Tối ưu hóa Pipeline:** Đã có hàm translate để kiểm tra trực quan kết quả dịch của mô hình trước và sau khi train.
- **Xác nhận môi trường:** GPU T4 trên Kaggle đã được cấu hình nhận diện thành công mô hình VietAI/envit5-translation ở chế độ float16.

4. Kế hoạch tuần tới

- **Thực thi quá trình Training:** Chạy mã nguồn huấn luyện trên tập 24.000 mẫu đã chuẩn bị.
- **Giám sát Loss:** Theo dõi biểu đồ hội tụ của loss function để điều chỉnh learning rate nếu cần thiết.
- **Đánh giá cuối kỳ:** Sau khi hoàn tất 1 epoch đầu tiên, tiến hành đo lại bộ 3 metric (BLEU, TER, METEOR) trên tập test 3.000 mẫu để so sánh với baseline của tuần 3.
- **Lưu trữ:** Xuất trọng số - LoRA weights.
-